2) Les données dont on dispose

On considère n ind. décrits par p vars quantitatives.

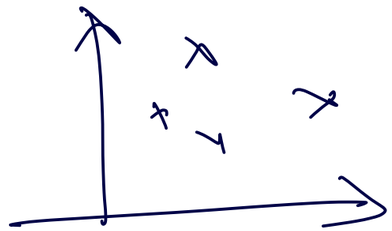
$$X = \begin{bmatrix} x_{11} & & x_{1p} \\ & & \\ x_{n1} & & x_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}$$

- n : nb d'ind
- p : nb de vars

Comment les représenter ?



1 var



2 vars



3 vars



p vars

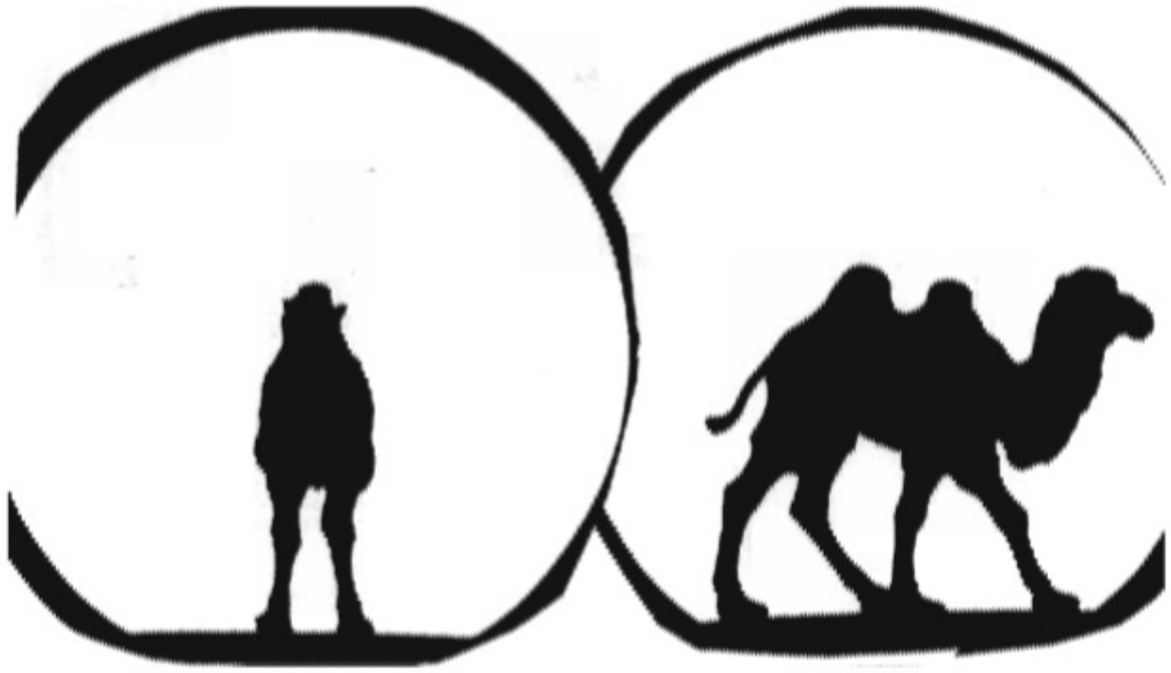
2) Pq réduire la dimension ?

PB = Comment représenter et interpréter les données qd p est grand ?

L'ACP est particulièrement intéressante pour :

- Visualiser des données de grandes dimension : en représentant les données sur 1 ou 2 axes principaux
- Résumer les données de grandes dim. : supprimer les redondances et mettre en valeurs les données qui portent la même info.
- Regrouper les ind. selon leurs similitudes : en résumant leurs caractéristiques

2) L'ACP ou l'art de choisir le meilleur angle de vue



Quel angle choisir pr mettre en évidence qu'il s'agit d'un chameau.

⇒ L'ACP cherche les directions de projections qui maximisent la variance des individus.

2) Comment comparer les individus ?

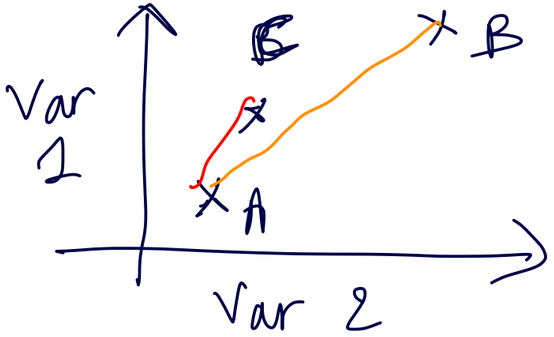
Chaque ind i est représenté par un pt x_i ds un espace à p dimensions =

$$X_i = (X_{i1}, \dots, X_{ip}) \in \mathbb{R}^p$$

↑ coord sur l'axe p

DISTANCE EUCLIDIENNE = pr mesurer la prox entre 2 ind on utilise la dist euclidienne

$$d(X_i, X_j) = \sqrt{\sum_{k=1}^{p} (X_{ik} - X_{jk})^2}$$



(A est + proche de B que de B)

distance faible = inds qui se ressemblent

distance élevée = inds ≠

2) Préparation des données - Centrage / Réduction

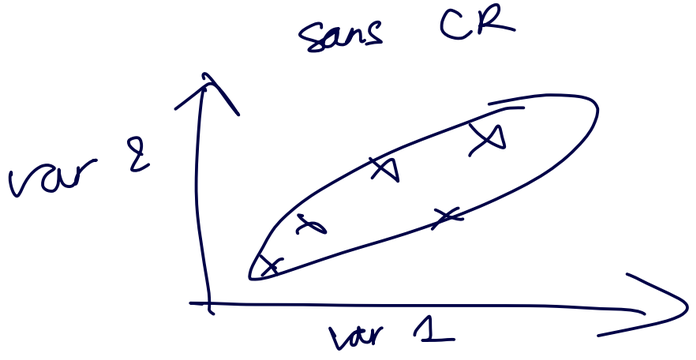
PROBLEME = Comment faire qd les données ont ≠ ordres de grandeurs (ex. kg & cm) ?

SOLUTION = Centrer - réduire X_j

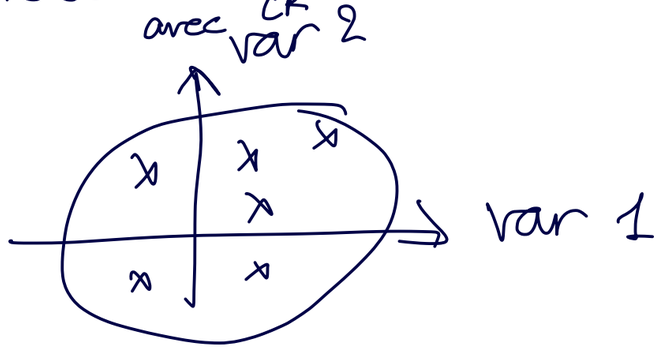
↳ centrer = soustraire la moyenne $\bar{X}$ à X_j
→ obtenir une variable de moy = 0

↳ réduire = diviser X_j par l'écart-type S_j
→ avoir un écart-type = 1

$$Z_{ij} = \frac{X_{ij} - \bar{X}_j}{S_j}$$ ← centrage ← réduction



on a des données non brutes par les échelles et comparables

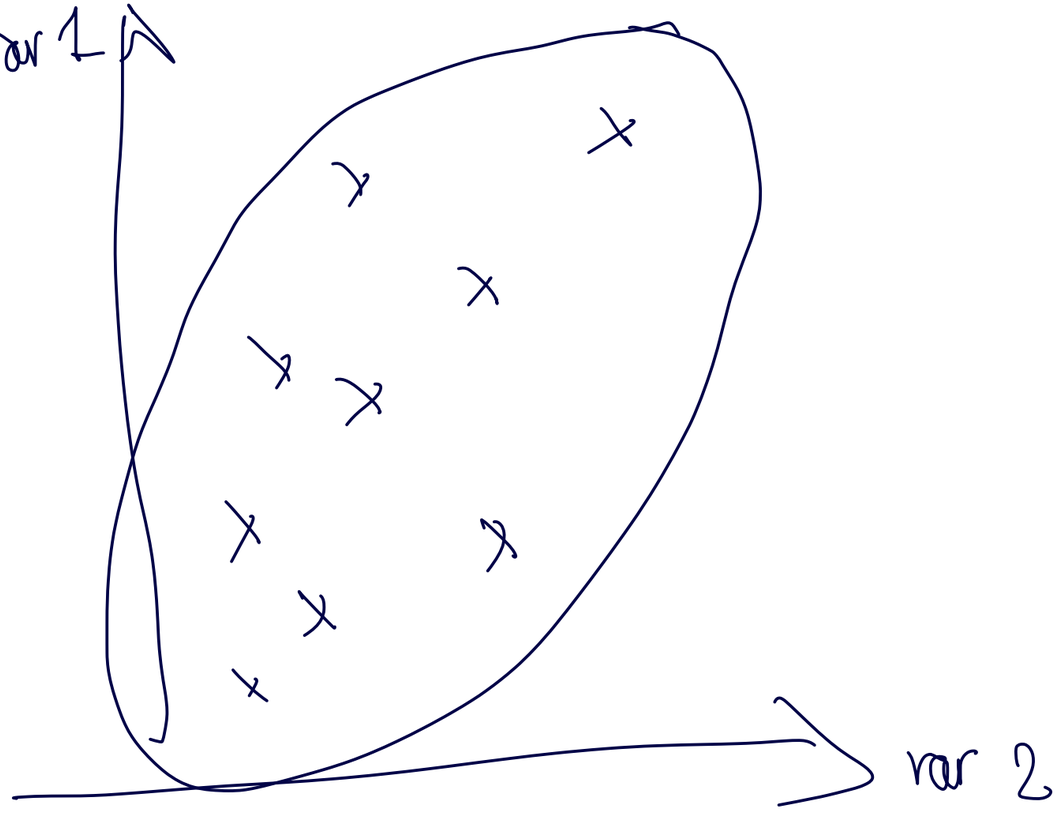


2) Représenter les ind. dans un espace de dim petite

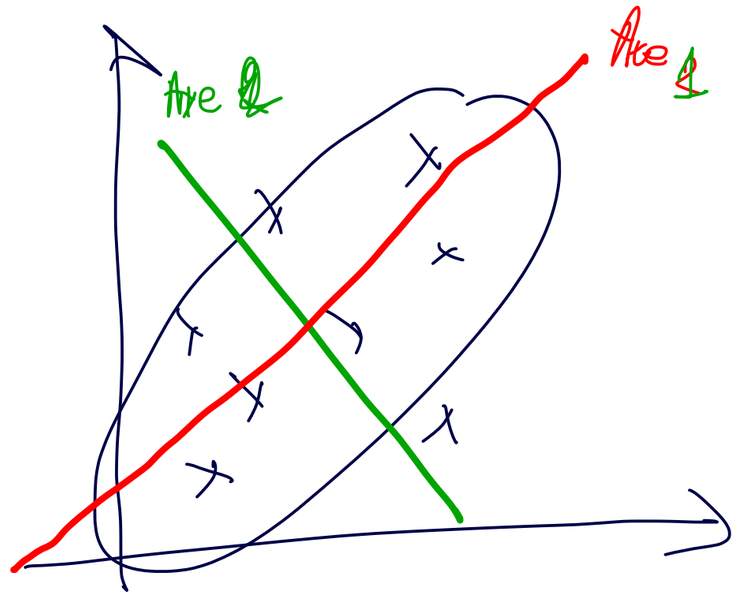
Soit n ind. décrits par p = 2 var quantitatives.

trouver les axes

DESCRIPTION DES DONNÉES ?



COMMENT CHOISIR UN NOUVEL AXE (UNE DIR) QUI PERMET DE RESUMER LES DONNÉES SUR UN SEUL AXE ?



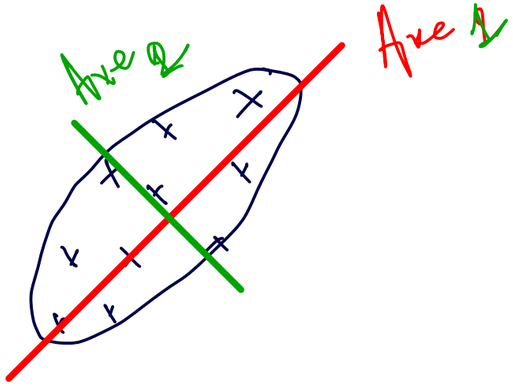
Axe 2 = données concentrées = peu d'infos

Axe 1 = données dispersées = bcp d'infos

⇒ On choisit un axe sur lequel les données sont dispersées (ie avec une grande variance)

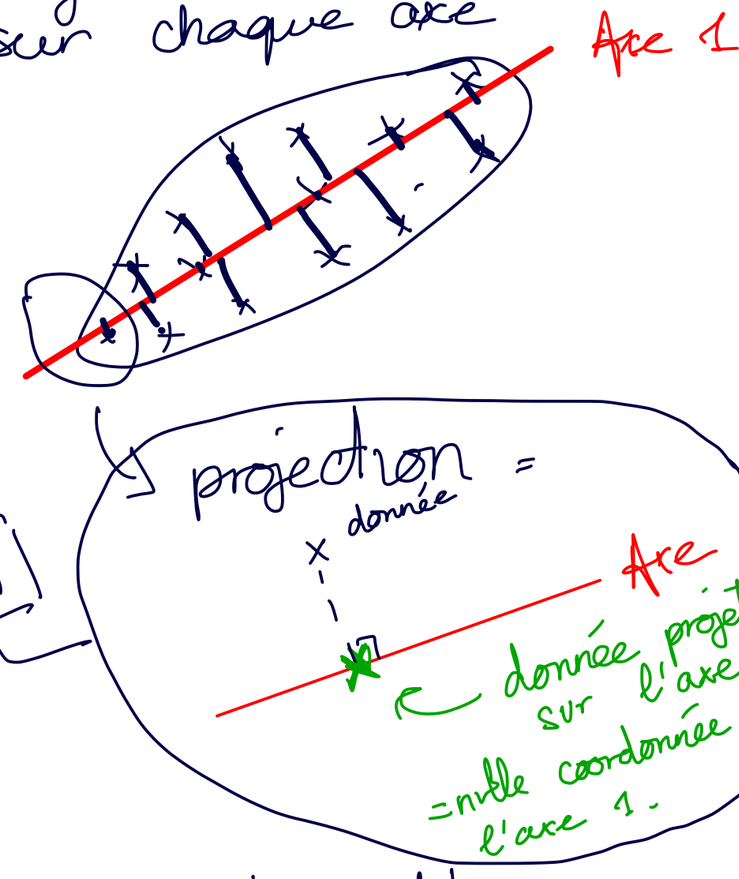
2) Représenter les ind. ds un espace de dim réduite - Composantes Principales

1. Rechercher les axes principaux



l'axe 1 maximise la variance
l'axe 2 est orthogonal il maximise ce qui reste

2. Projeter les individus sur chaque axe



COMPOSANTE PRINCIPALE

Une composante principale est une var quanti obtenue en projetant les inds sur l'axe principal t_q

$$PC_k = a_{k1} Z_1 + \dots + a_{kp} Z_k$$

où $Z_1, \dots, Z_p$ sont les vars centrées réduites et le a_{kj} les vars définissant l'axe k.

2) Choisir les axes et composantes principales

OBJECTIF = Trouver les axes qui permettent de conserver un max de dispersion des ind après projection

CONSTRUCTION =

↑ on parle de var expliquée.

↳ Axe 1 = direction qui maximise la dispersion
→ PC_1 = projections des ind sur l'axe 1

↳ Axe 2 = direction orthogonale à l'axe
→ PC_2 = ...

↳ Axes suivants = on les construit selon le m̂ principe orthogonalement aux autres axes.

Note

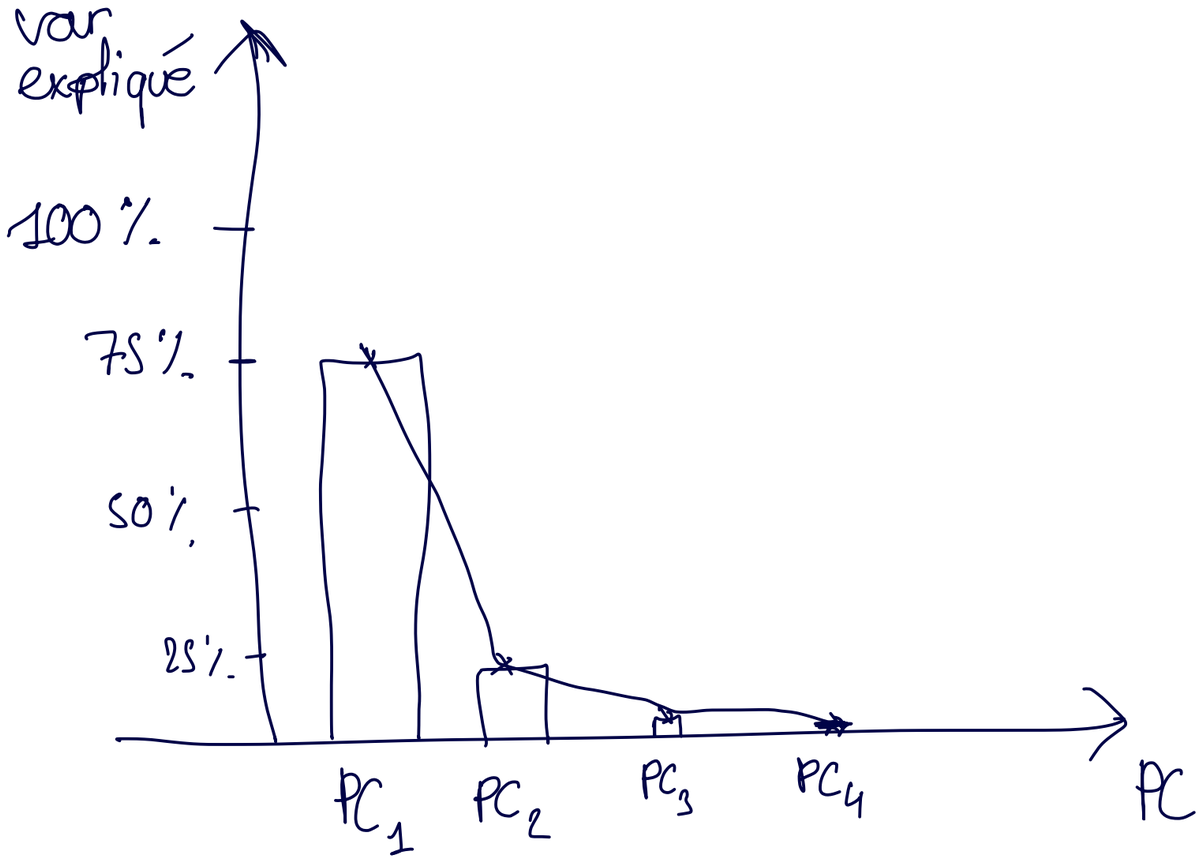
Les comp. principales sont des var non corrélées entre elles classées par ordre ↘ de var expliquée

2) Combien de composantes choisir ?

DEUX MÉTHODES :

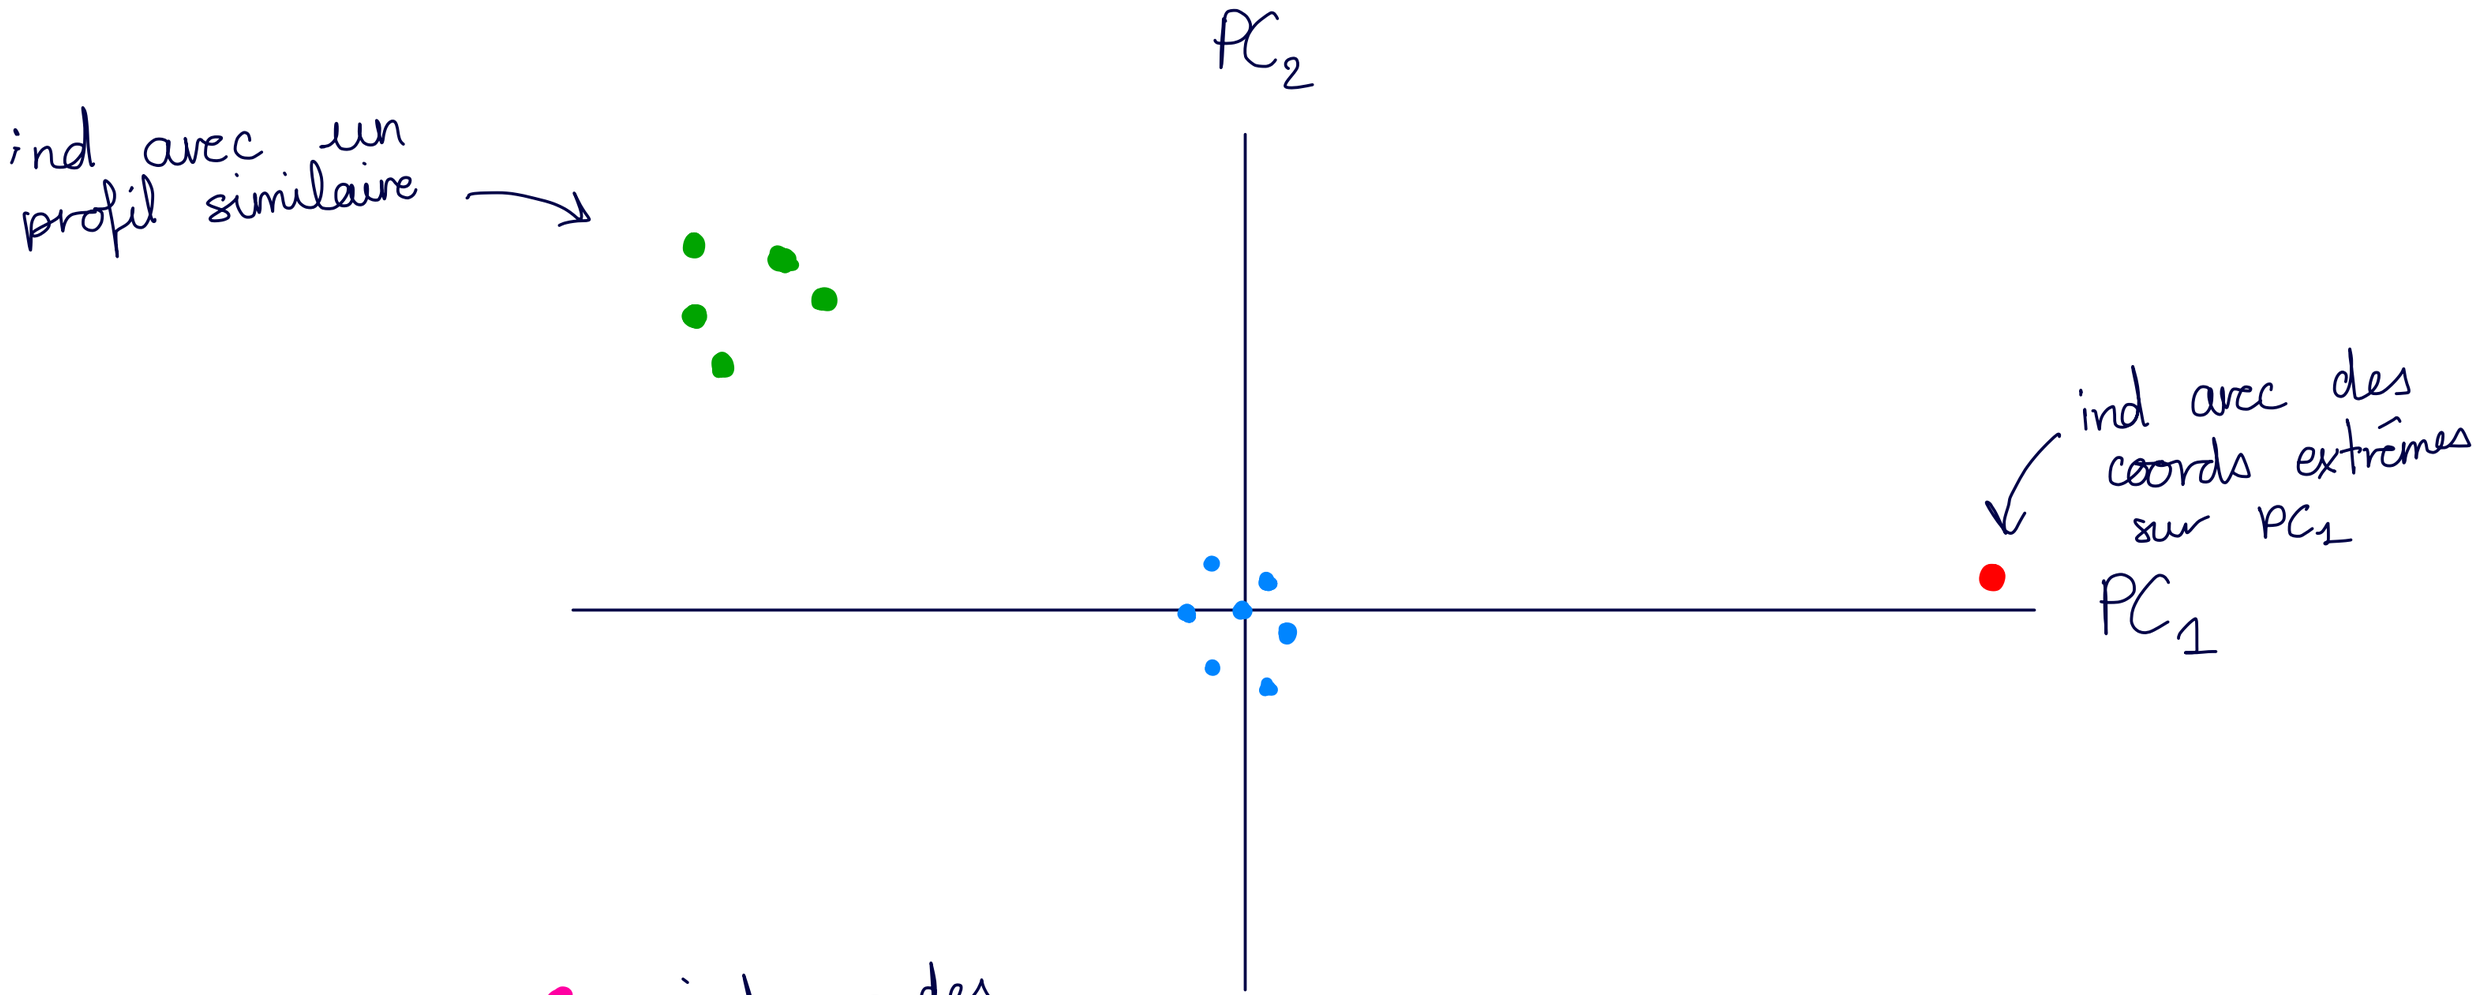
↳ **Critère du coude** : on repère le moment où si on ajoute une nouvelle comp on récupère peu d'info (visuellement ds le coude ✳)

↳ **Seuil** : exp qd on a expliqué 80% de la var.



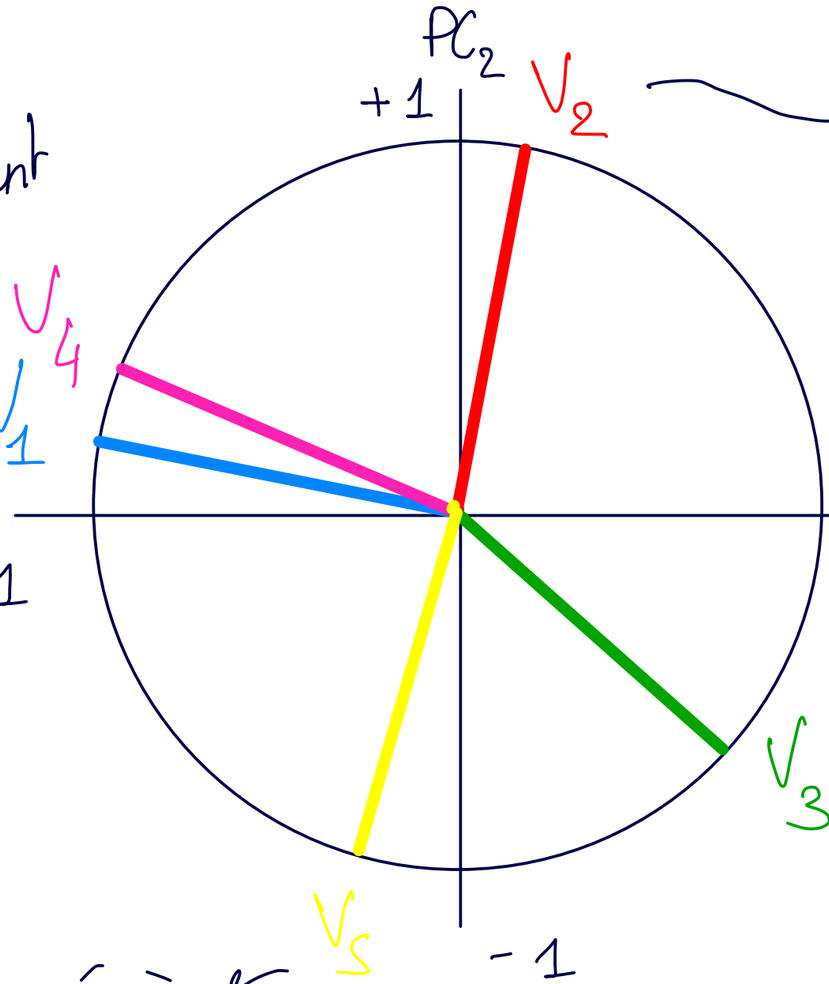
Le choix dépend de l'objectif de l'analyse (visu vs résumer) = il faut trouver un compromis entre peu d'axe et bcp de var expliquée.

3) Visualisation - Graphique des individus



Le graphique des ind permet d'étudier les ressemblances entre eux sur les composantes

3) Visualisation - Cercle des corrélations



V_1 et V_4 sont fortement corrélés négativement entre eux et à PC_1

qd V_1 ↑, V_4 aussi

V_1 et V_4 explique PC_1

V_2 est fortement corrélée positivement à PC_2

V_2 explique PC_2

V_3 → V_3 est corrélée à l'axe 1 et le 2

V_3 explique un peu PC_1 et PC_2

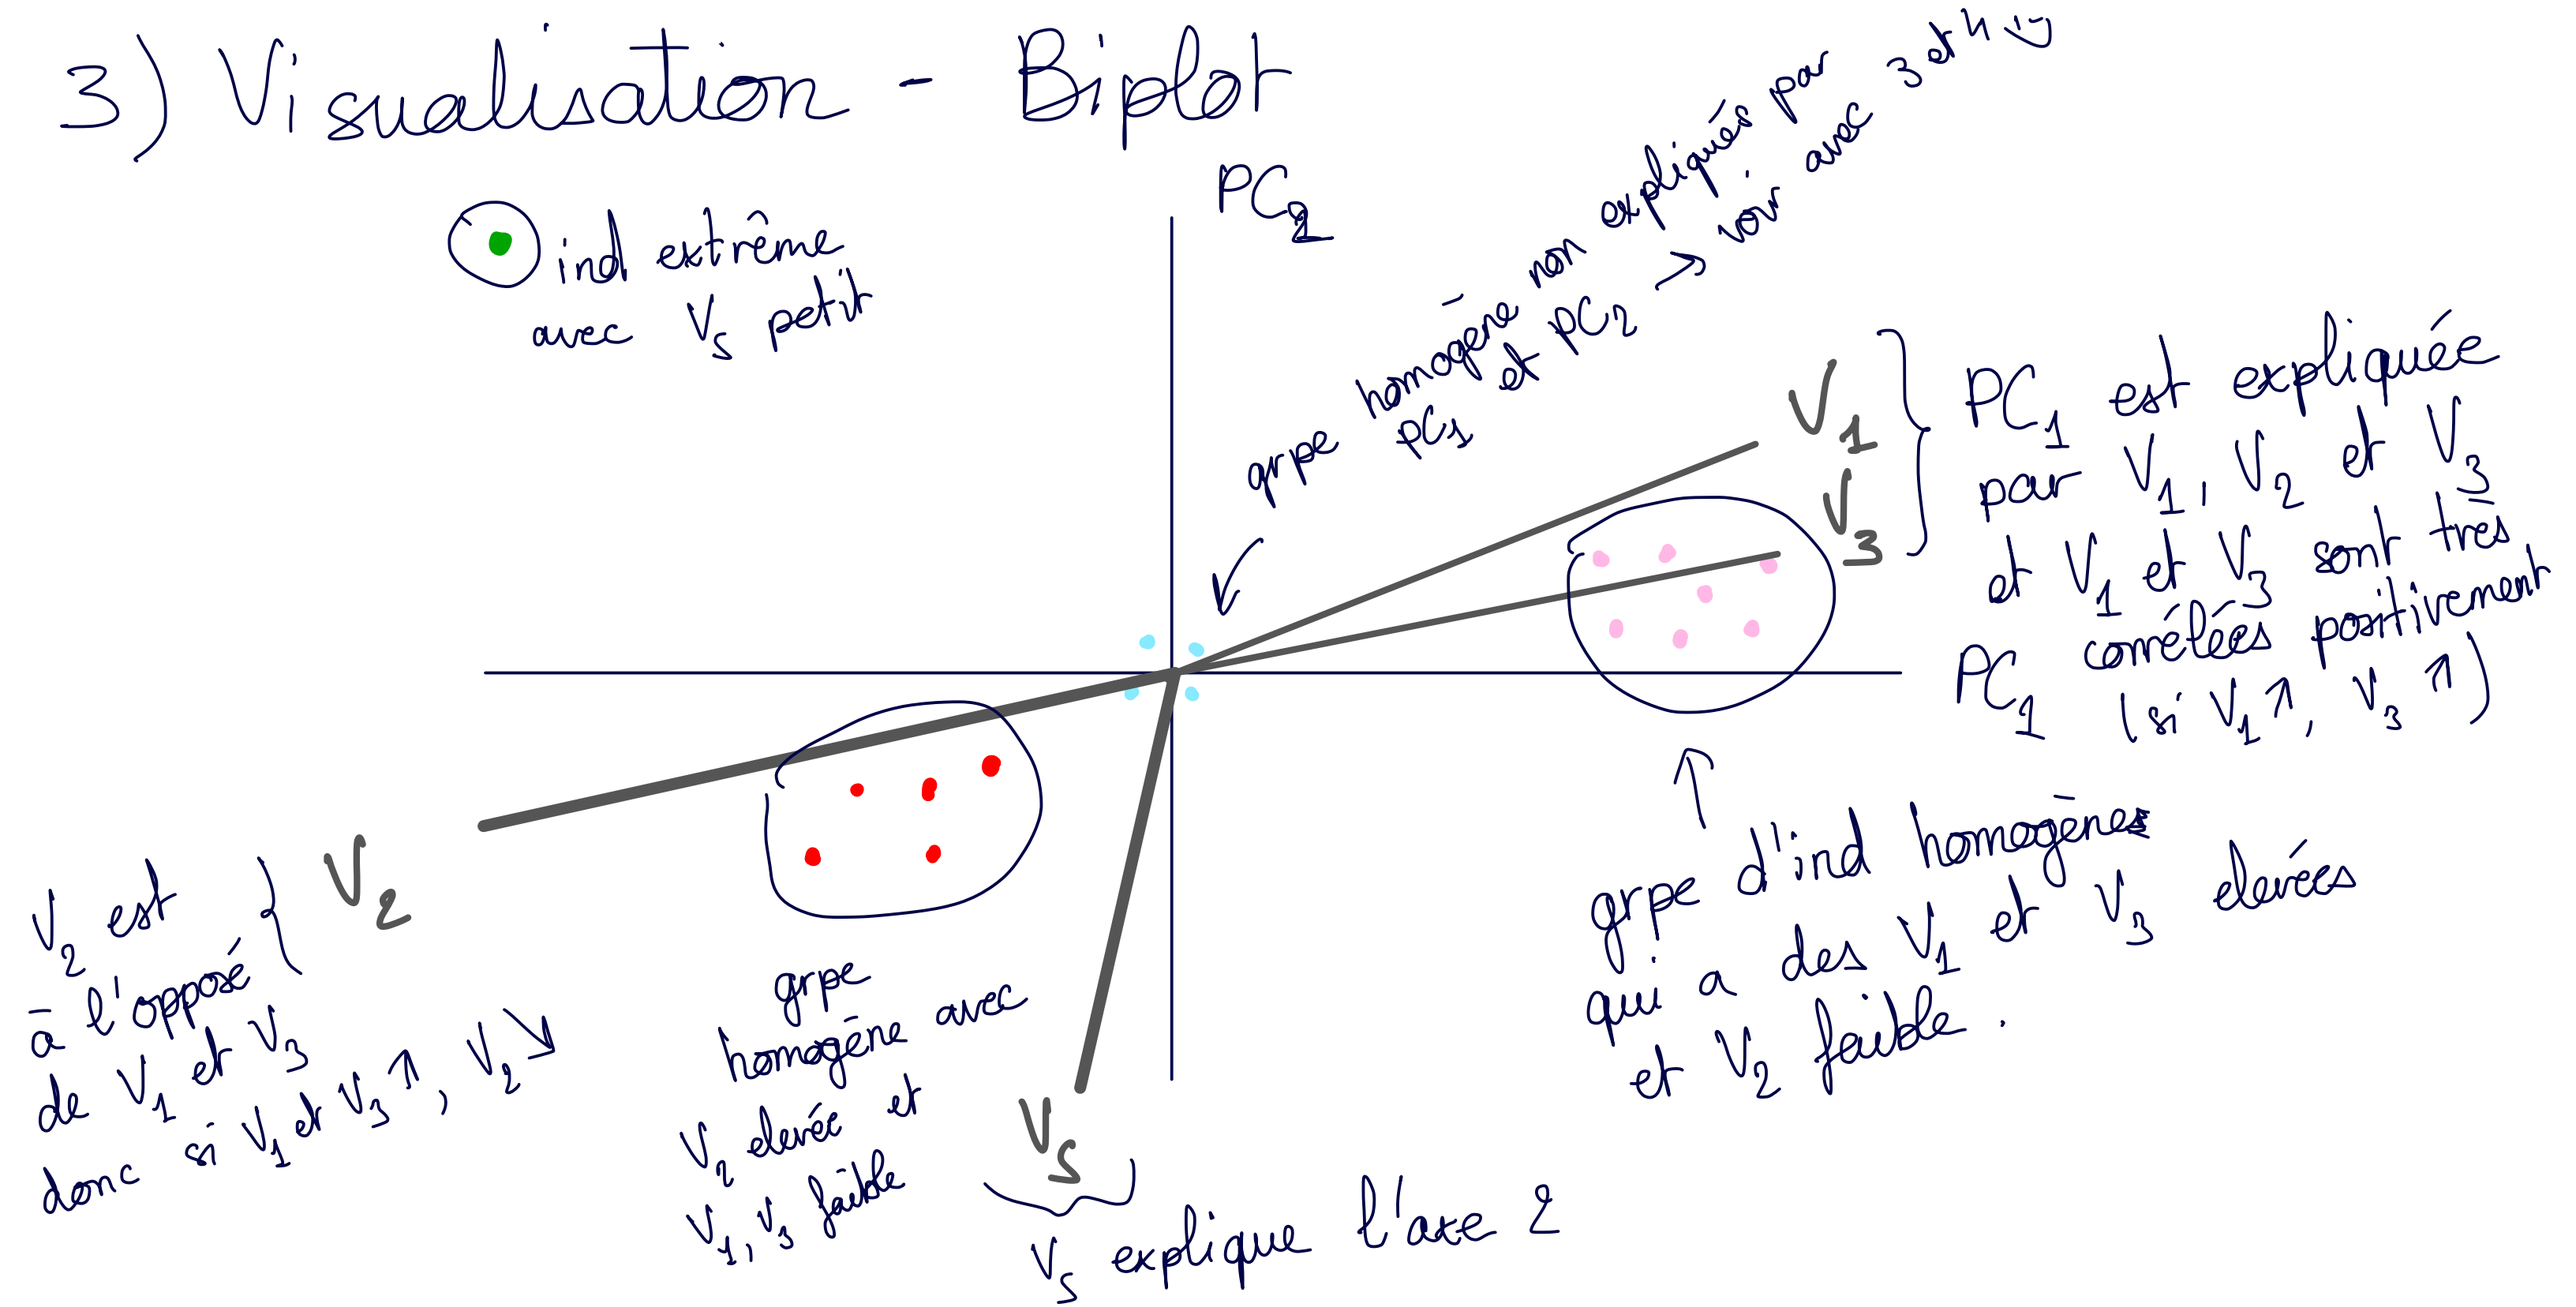
V_5 est opposée à V_2

qd V_5 ↑, V_2 ↓

V_5 explique PC_2

le cercle de corr. permet d'interpréter les relations entre les variables et leur association avec les composantes principales (ie si elles expliquent une comp)

3) Visualisation - Biplot



Le biplot permet de relier la pos des ind aux vars qui le caractérisent. Les ind situés ds la dir d'une var présentent des vals élevées pr elles, et faibles s'ils sont opposés

4) Application aux manchots avec R

To Do :

1) Préparer les données

2) Centrer réduire

3) Réaliser l'ACP

4) Choisir le nb de CP

5) Interpréter / Visualiser

4) Application - 1 - Prepa données

Code

- selection données
- nettoyage narm
- summary

Sortie

Summary

S1 Application - 2 - Centrer réduire

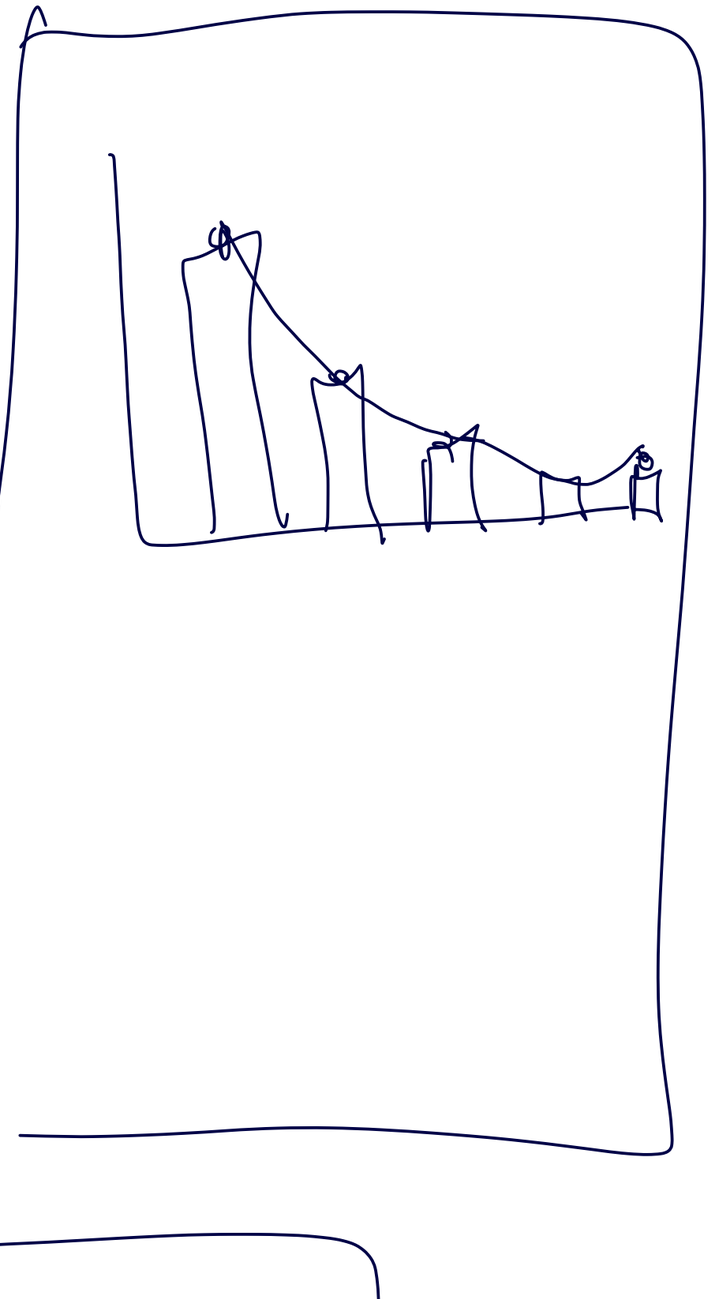
fct

tableau

val	val CR

5) Appli ACP & Selection nb CP

Code

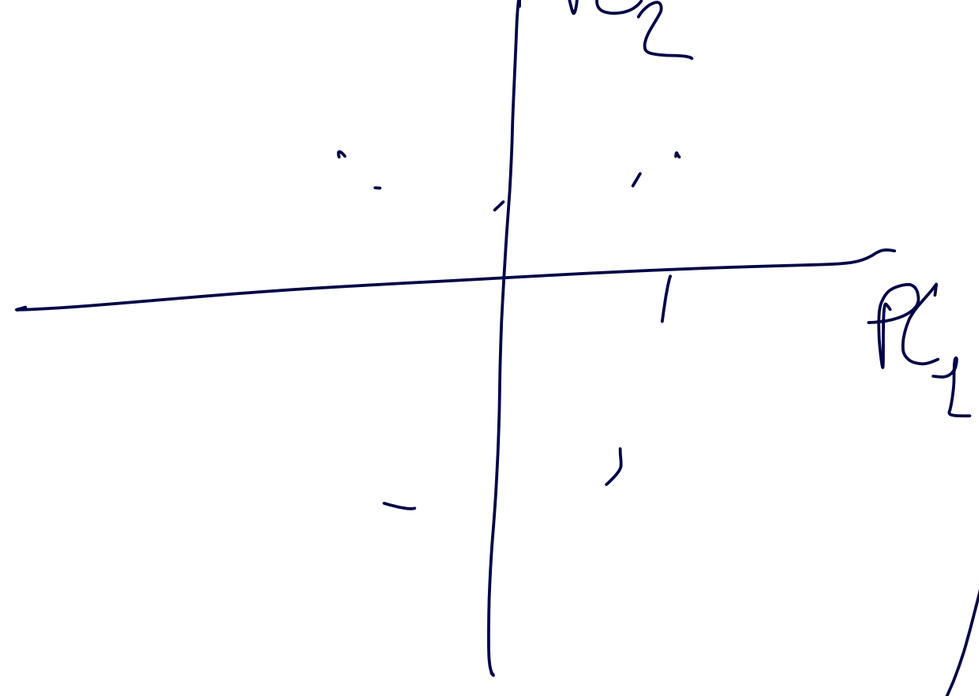


choix

5) Visualisation - Ind

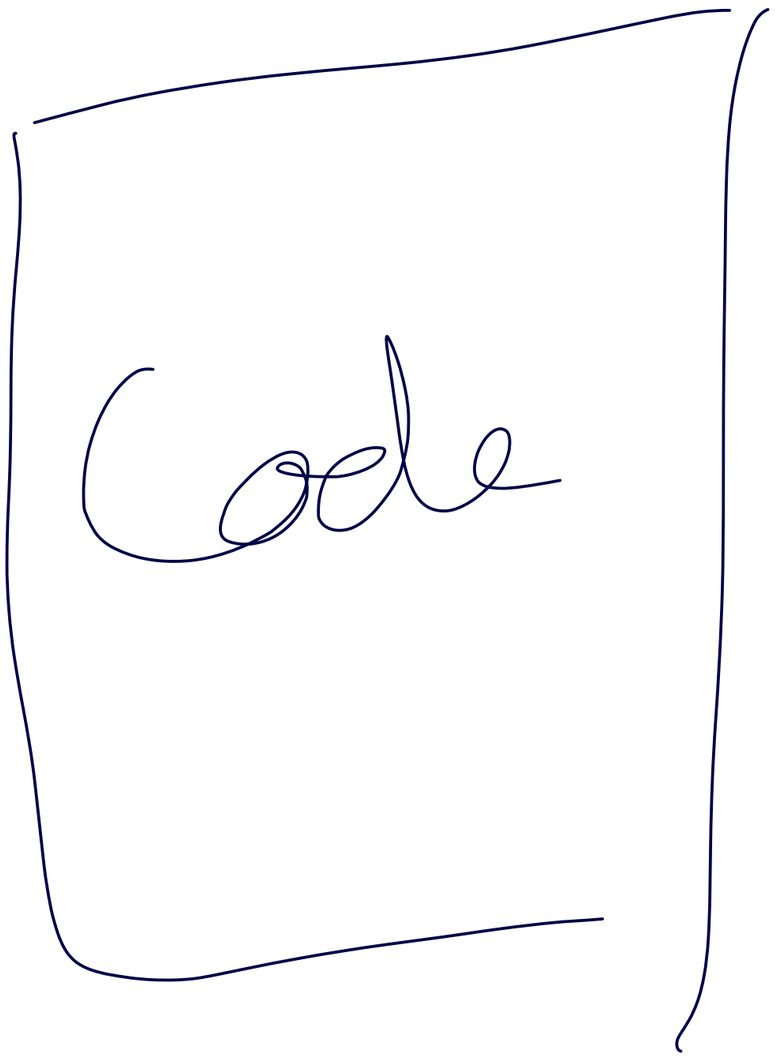
Code

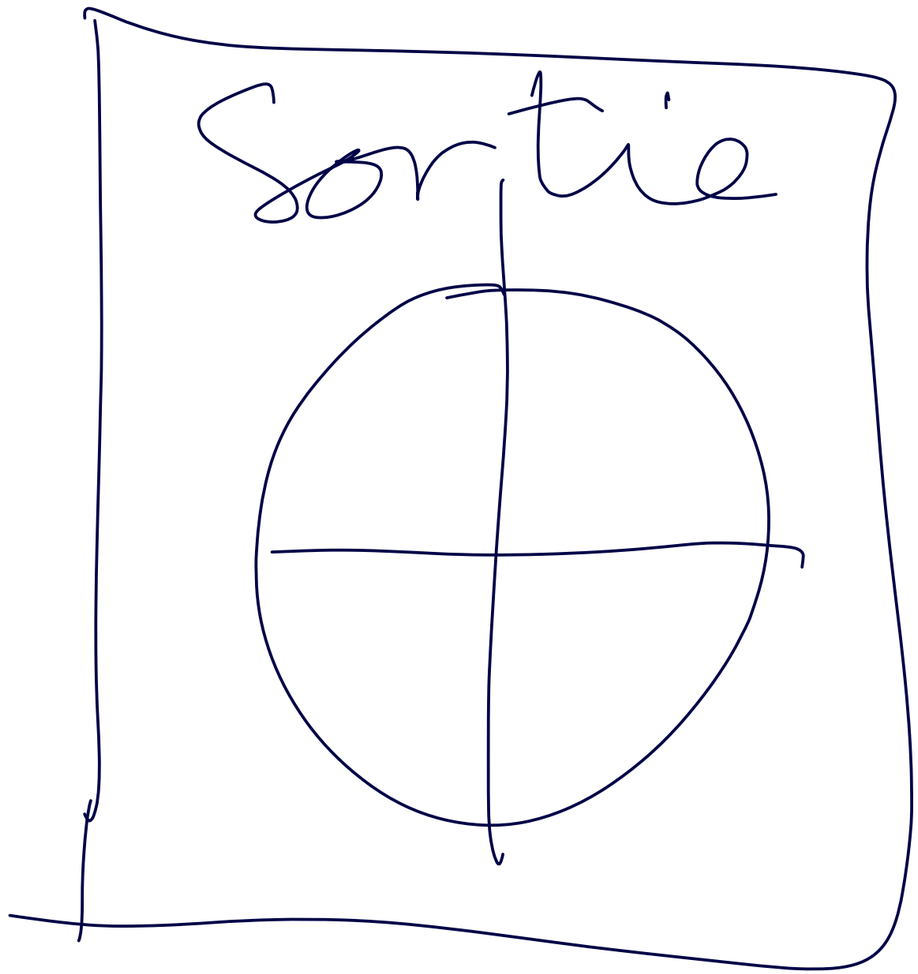
Sortie



INTERPRETATION

5) Visualisation - Cercle con



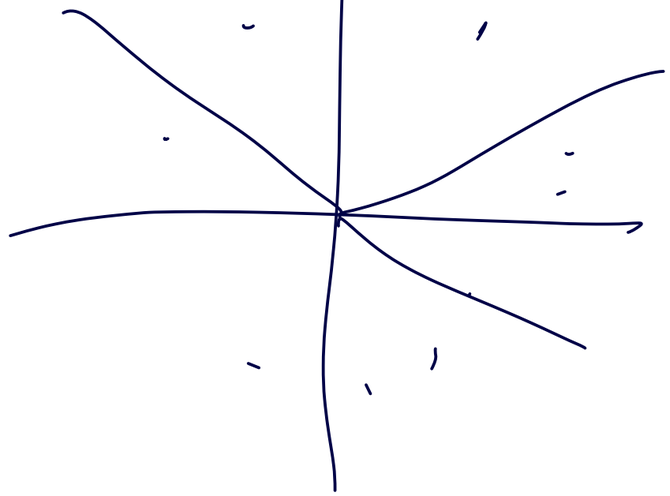


INTERPRETATION

5) Visualisation - Biplot

Code

Sortie



INTERPRETATION