1) Ecriture du modèle - Définitions

Soit i un ind et j les comp de X. On mesure sur l'ind i Y_i la var à expliquer & les X_{ij} les vars explicatives. Le modèle s'écrit tq

$$Y_i = \underbrace{\beta_0}_{\text{cste (ord à l'origine)}} + \sum_{j=1}^{5} \underbrace{\beta_j}_{\text{coeff (effet j)}} X_{ij} + \underbrace{\varepsilon_i}_{\text{bruit}}$$

Note

Si $J = 1$, on a un modèle linéaire simple

1) Pq utiliser un modèle linéaire multiple ?

☰ Une ♂ rep peut être expliquée par plusieurs var exp

⁝ Les vars exp. peuvent être liées entre elles

✓ L'association de chaque var et la rep peut être étudiée indépendamment

> la reg. multiple permet donc d'étudier le lien entre plusieurs var et la rep, en tenant compte de leurs effets ind. resp

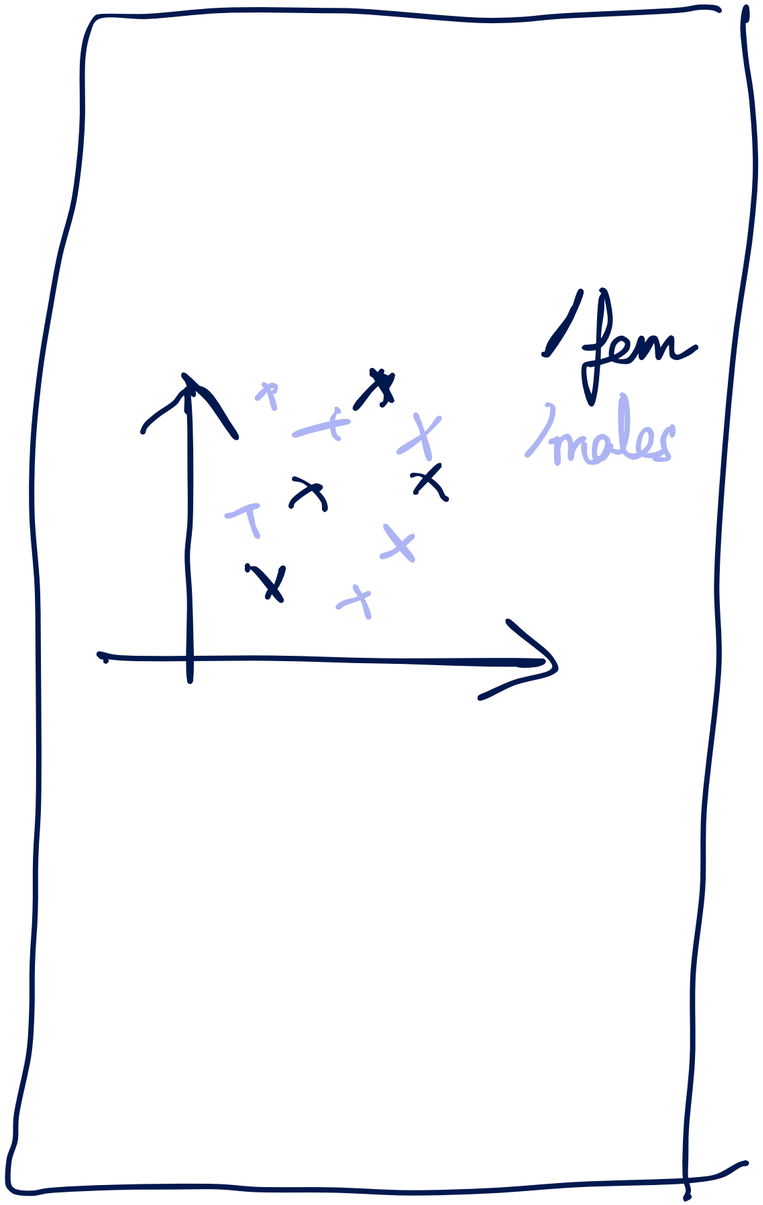
1) Ecriture du modèle - Exemple

FL

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \varepsilon_i$$

- β_0 : effet moy
- β_1 : effet CL
- β_2 : sexe
- ε_i : bruit

On va chercher un plan



1) Les hyps à vérifier

- INDEPENDANCE

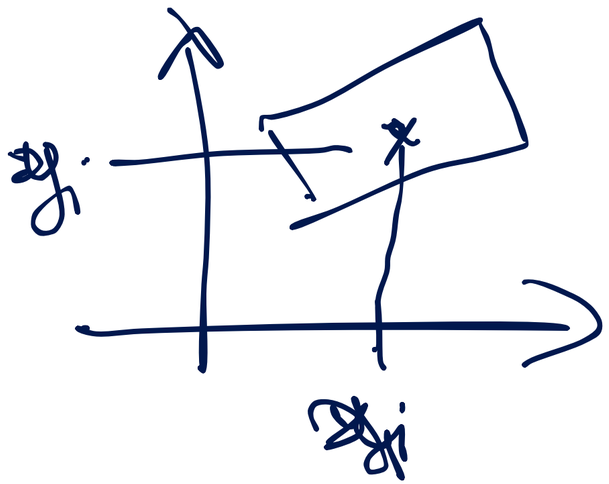
Les ind. sont ll

1) Les hyp à vérifier

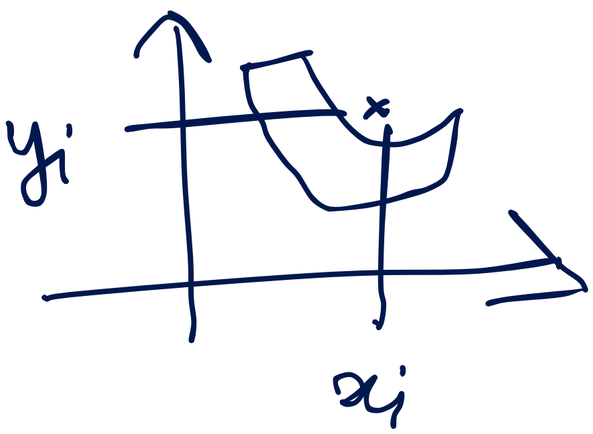
LINEARITÉ : à x_i fixé, $\mathbb{E}(\varepsilon_i | x_i) = 0$

$\rightarrow \mathbb{E}(Y_i) = \beta_0 + \sum_{j=1}^{J} \beta_j X_{ij}$

lin.



non lin.



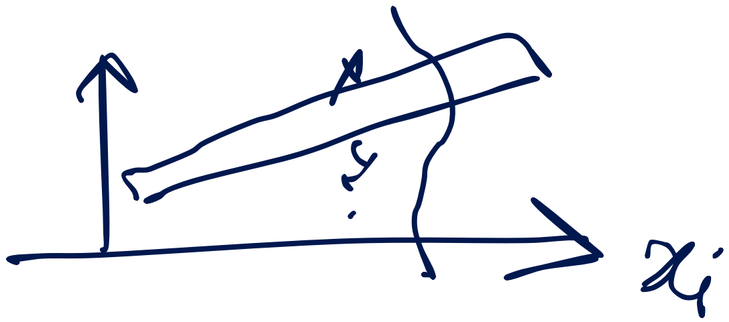
pour une val. x_i, l'obs coupe le plan en son centre

1) Les hyps à vérifier

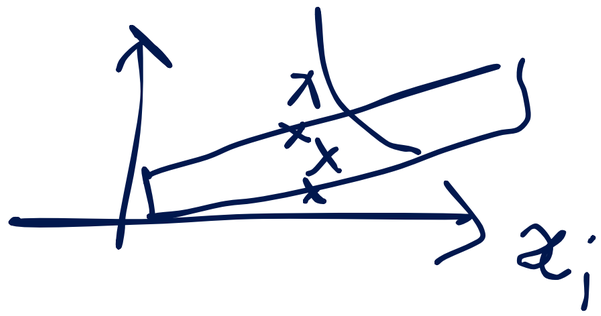
NORMALITÉ : à x_i fixé, $\varepsilon_i | x_i \sim \mathcal{N}(0, \sigma^2)$,

$y_i \sim \mathcal{N}(\beta_0 + \sum \beta_j x_{ij}, \sigma^2)$

cas normal



cas non normal

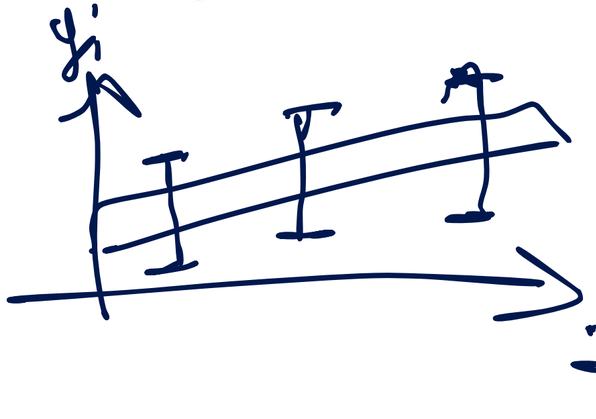


A x fixé, les points obs y sont distribués selon une normale.

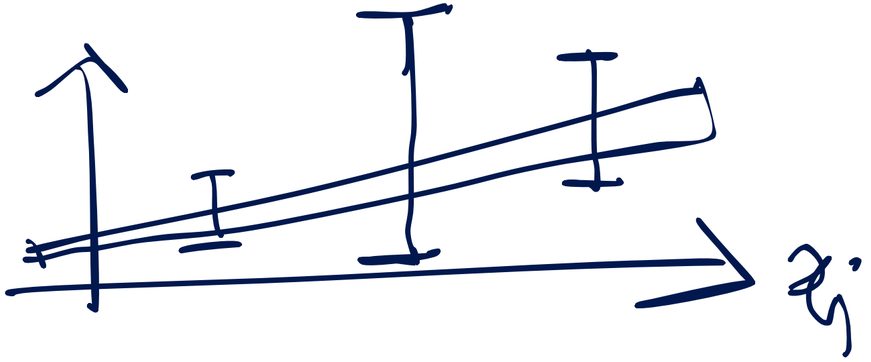
1) les hyp à vérifier

HOMOSCEDASTICITÉ : $Var(\varepsilon_i | x_i) = \sigma_i^2$ $\forall i$, la var des Y est cste

cas homoscedastique



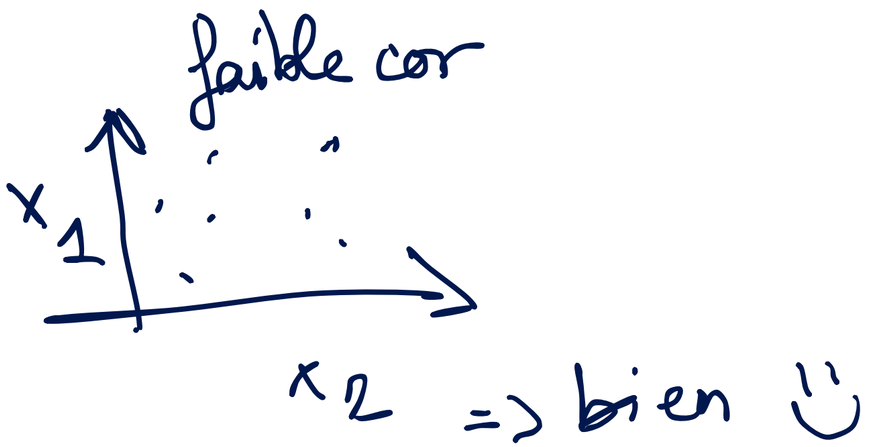
cas hétéroscedastique



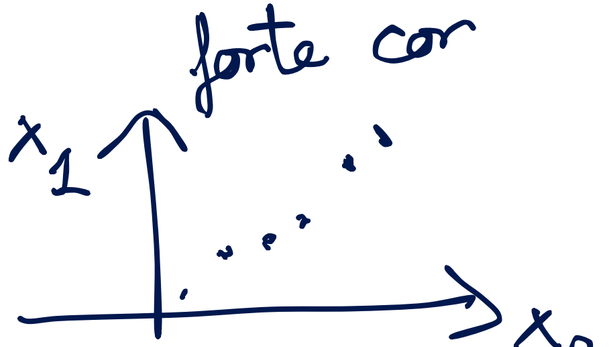
la dispersion de Y est cste $\forall$ val de x_i

1) les hyp à vérifier

NON MULTICOLINEARITÉ = aucune var explicative ne s'exprime comme une combinaison linéaire des autres.



=> bien ☺



=> pas bien ☹

Les variables X ne sont pas de comb. lin. les unes des autres

1) Verfs des hyps

INDEP : ✓

LIN : ✓

Normalité : ✓

Homoscedasticité : ✓

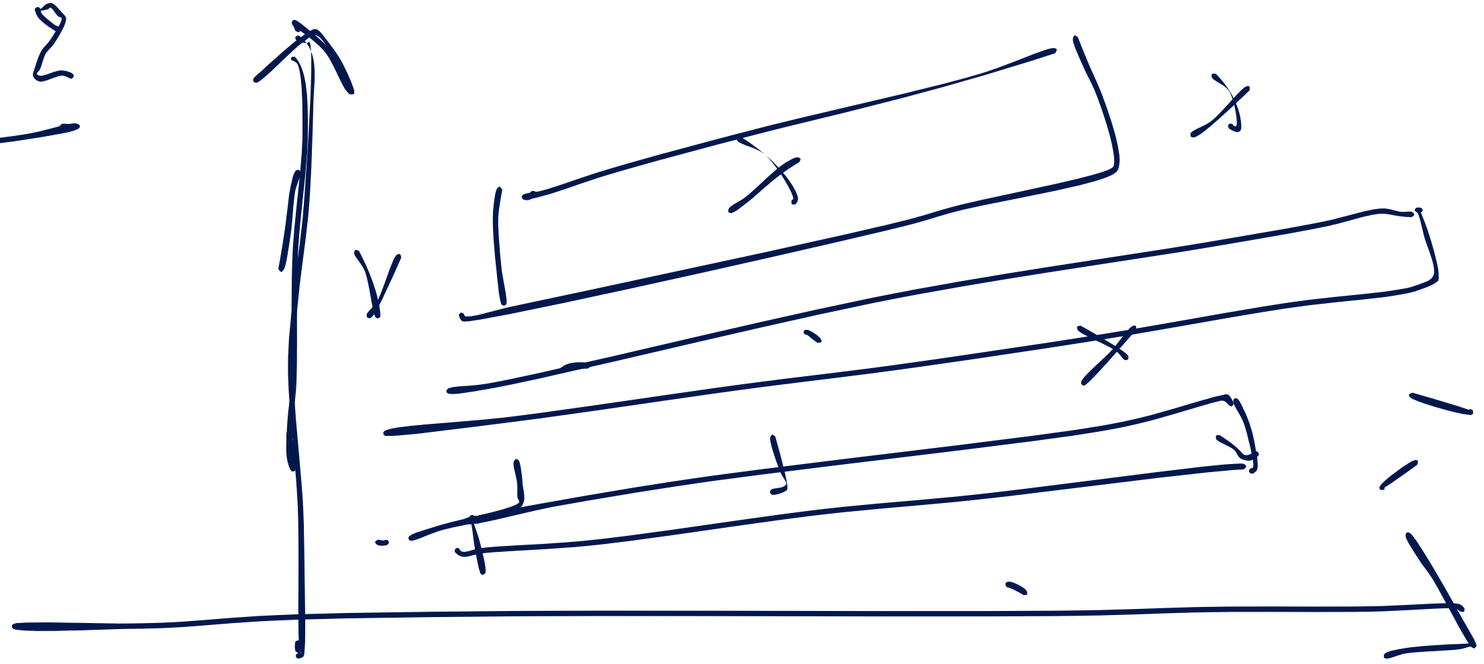
Non multicolinéarité : ✓

graphique pour vérif les hyps

2) Méthode des moindres carrés

La reg lin multiple permet de trouver $\beta_0, \beta_1, \beta_2, \ldots, \beta_J$ qui décrivent le mieux les données

en dim 2



(quel est le meilleur plan qui explique nos données)

2) Estimation -- Notations

- β_0 et $\beta_1, \dots, \beta_J$: params
  - → $\hat{\beta}_0, \dots$: params predits

- y_i : obs
  - → $\hat{y}_i$: predictions
- $e_i = y_i - \hat{y}_i$

graphique

☺

on cherche $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_J$ tq

$$\hat{\beta} = \text{argmin} \sum_{i=1} \left[y_i - \left(\beta_0 + \sum X_{ij} \beta_j \right) \right]^2$$

2) Résolution

on cherche $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_j$ tq

$$\hat{\beta} = \operatorname{argmin} \sum \left[y_i - \left(\beta_0 + \sum x_{ij} \beta_j \right) \right]^2$$

En dérivant, on obtient comme solution

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

$\Rightarrow$ En pratique, on le calcule numériquement.

2) Résolution - Exemple

$\hat{\beta}_0 = ?$

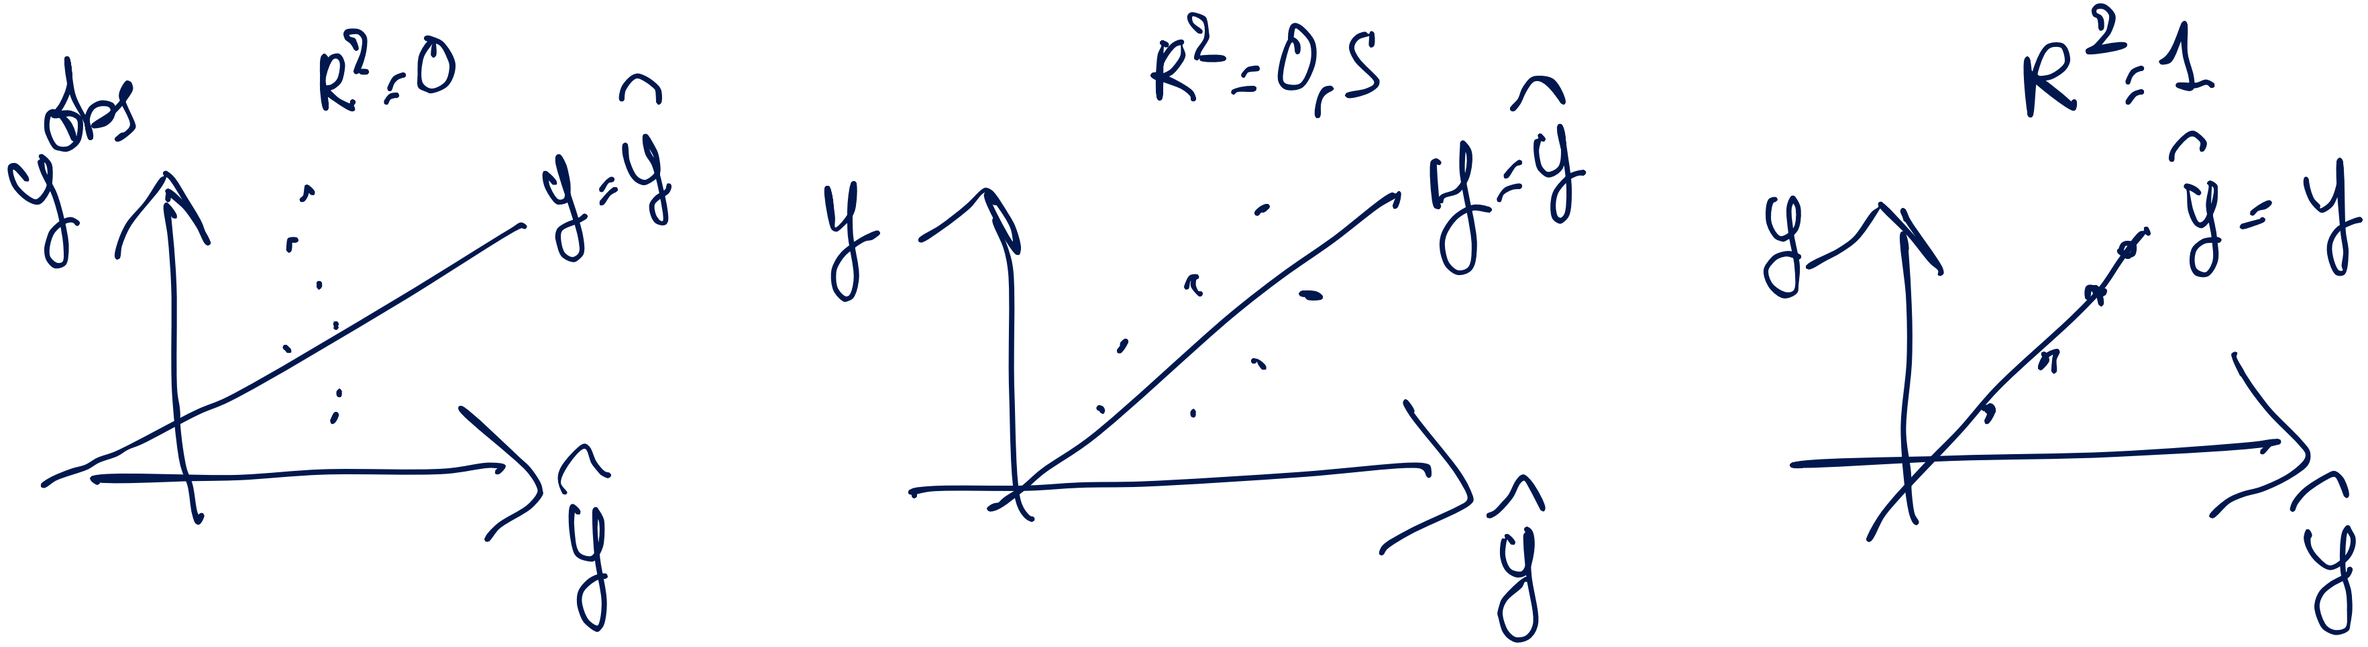
$\hat{\beta}_1 = ?$

$\hat{\beta}_2 = ?$



3) Le R^2 – Intuition

R^2 mesure le % de var de Y expliqué par le modèle.



$0 < R^2 < 1$

3) Le R^2 - Mathématiquement

3 Qualité de la droite de régression avec R^2 : Calcul

$$R^2 = \frac{\sum_{i=1}^{N}(\hat{y}_i - \bar{y})^2}{\sum_{i=1}^{N}(\hat{y}_i - y_i)^2} = 1 - \frac{\sum_{i=1}^{N}(y_i - \bar{y})^2}{\sum_{i=1}^{N}(y_i - \bar{y})^2},$$

où :

- $\sum_{i=1}^{N}(\hat{y}_i - \bar{y})^2$ = somme des carrés expliqués
  $\longrightarrow$ Ce que le modèle **EXPLIQUE**.
- $\sum_{i=1}^{N}(y_i - \bar{y})^2$ = somme des erreurs/résidus
  $\longrightarrow$ Ce que le modèle **N'EXPLIQUE PAS**.
- $\sum_{i=1}^{N}(y_i - \bar{y})^2$ = variabilité totale
  $= \sum_{i=1}^{N}(\hat{y}_i - \bar{y})^2 + \sum_{i=1}^{N}(\hat{y}_i - y_i)^2$.

3) Le R^2 - Exemple

$$R^2 = 1 - \frac{\sum_{i=1}^{n} (y_i - \hat{y})^2}{\sum (y_i - \bar{y})^2}$$

$= 1 - \ldots$

$= \ldots$

plan de reg.

3) Note - R^2 ajusté

$$R^2_{\text{ajusté}} = 1 - (1 - R^2)\frac{n - 1}{n - J - 1}$$

→ prise en compte du nb de var exp. (J)

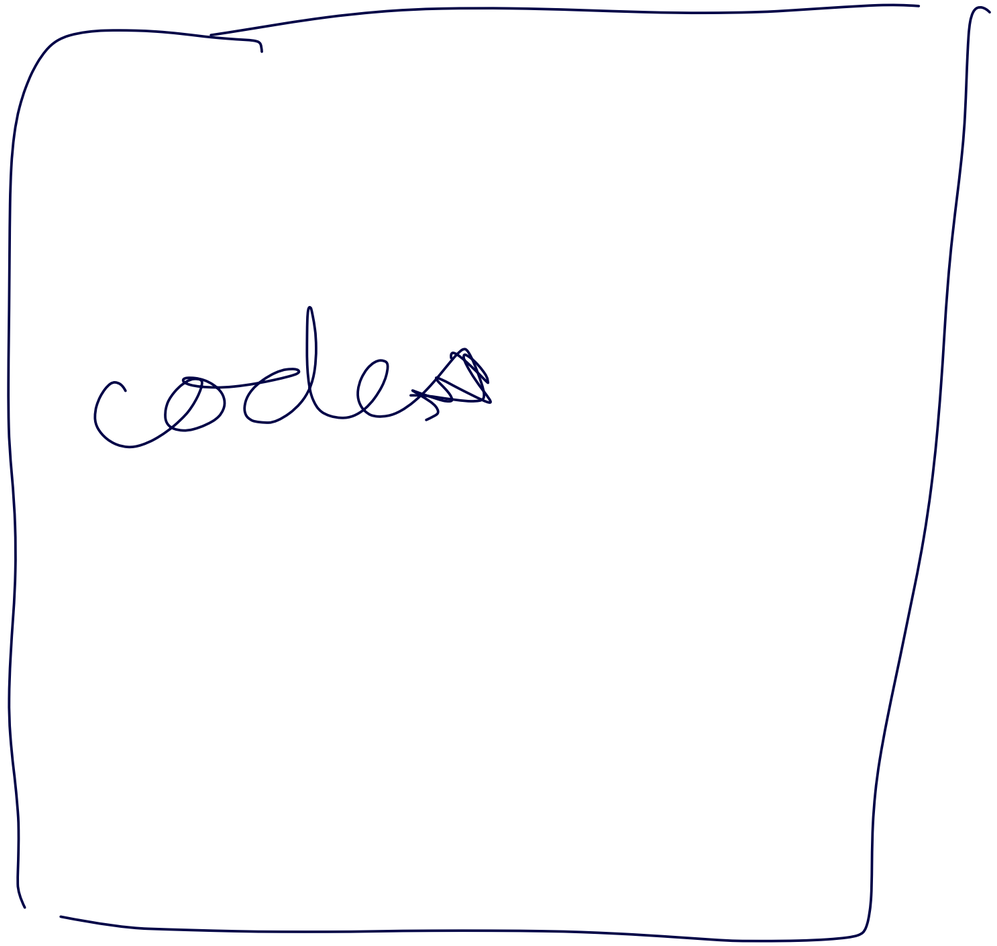
→ utile pour comparer ≠ modèles avec des nb de vars ≠

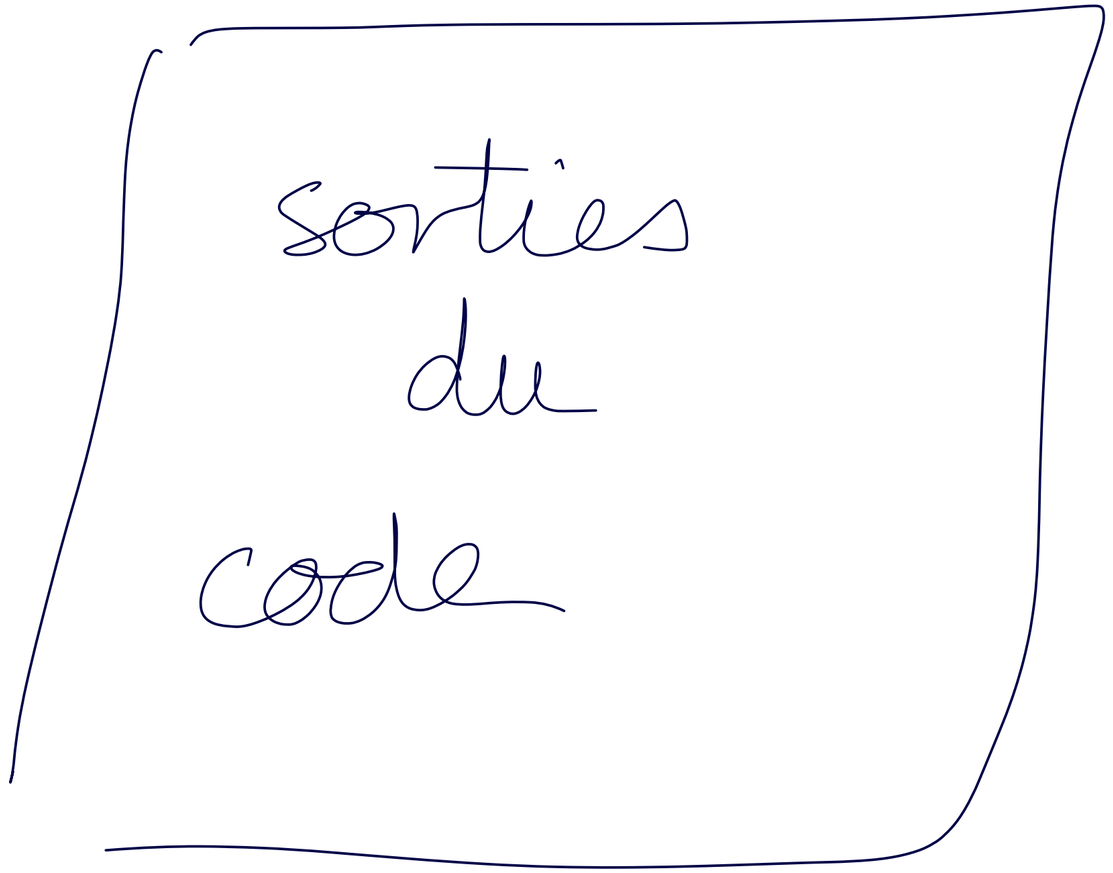
4) Application avec R

To Do :

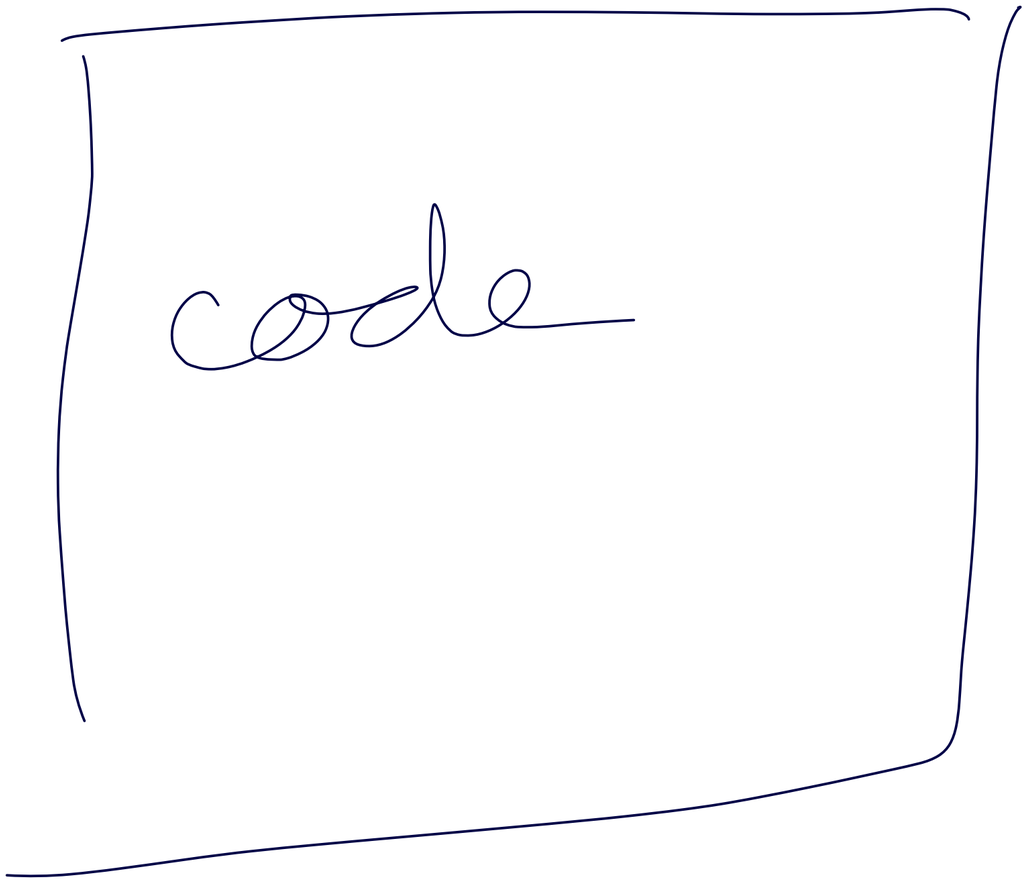
1) Explorer les données (nuages de pts)
2) Vérifier les hyp
3) Reg lin & calcul du $R^2_{ajusté}$
4) Interprétation

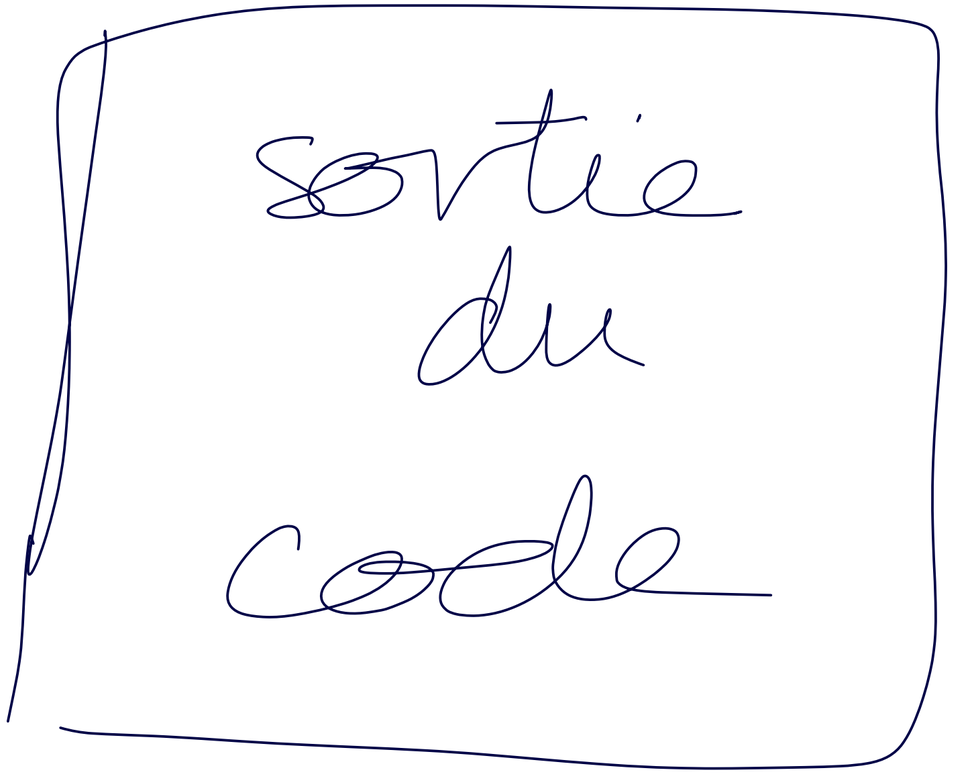
4) Nuage de pts





4) Regression - Appli





4) Appli - Interpretation

