1) Ecriture du modèle - Définitions

Soit i un ind ($i = 1, \dots, n$), j les comp de X ($j = 1, \dots, J$) et k les comp de Y (réponses $k = 1, \dots, K$). Le modèle s'écrit tq :

$$\underbrace{y_{ik}}_{\text{rep}^{\text{se}} \text{ mesurée chez ind } i} = \underbrace{\beta_{0k}}_{\substack{\text{cste pr la} \\ \text{rep } k}} + \underbrace{\sum \beta_{jk} x_{ij}}_{\substack{\text{coeff pr} \\ \text{var } x_j \text{ pr} \\ \text{rep } k}} + \underbrace{\varepsilon_{ik}}_{\substack{\text{bruit} \\ \text{ind } i, \\ \text{rep } k}}$$

Note

reg $\neq$ modèle

1) Ecriture matricielle du modèle

$$Y = X\beta + E$$

$$\begin{pmatrix} y_{11} & y_{1k} \\ y_{n1} & y_{nk} \end{pmatrix} = \begin{pmatrix} 1 & x_{11} & x_{1J} \\ | & & \\ 1 & x_{n1} & x_{nJ} \end{pmatrix} \begin{pmatrix} \beta_{01} & \beta_{0k} \\ \vdots & \\ \beta_{n1} & \beta_{nk} \end{pmatrix} + \begin{pmatrix} \varepsilon_{11} & \varepsilon_{1k} \\ \varepsilon_{n1} & \varepsilon_{nk} \end{pmatrix}$$

où $Y \in \mathbb{R}^{n \times k}$, $X \in \mathbb{R}^{n \times (J+1)}$, $\beta \in \mathbb{R}^{(J+1)k}$ et $E \in \mathbb{R}^{nk}$

1) Pq utiliser un modèle lin multivarié ?

Plusieurs reps peuvent être liées

- Les erreurs des ≠ reponses peuvent être corrélées

$$Var(\varepsilon_i | X_i) = \Sigma = \begin{pmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{pmatrix}$$

↖ var (top-left) ; ↖ var (bottom-right) ; ↖ cov (off-diagonal)

V/ L'association d'une var explicative et de plusieurs rep peut être testée conjointement

> La reg multivariée permet d'étudier simultanément ≠ rep quanti en tenant compte des corrélations entre elles

1) Ecriture du modèle - Exemple

$$\begin{cases} CL_i = \beta_{01} + \beta_{11} FL_i + \beta_{21} Sexe_i + \varepsilon_{i1} \\ CW_i = \beta_{02} + \beta_{12} FL_i + \beta_{22} Sexe_i + \varepsilon_{i2} \end{cases}$$

β_{21} : ≠ entre CL moy entre les sexes à FL fixé

β_{12} : asso FL et CL pr 1 sexe fixé

ε_{i2} : bruit

où Sexe = 0/1.

graphique ?!
Scatterplot ?!

1) Hyp à vérifier

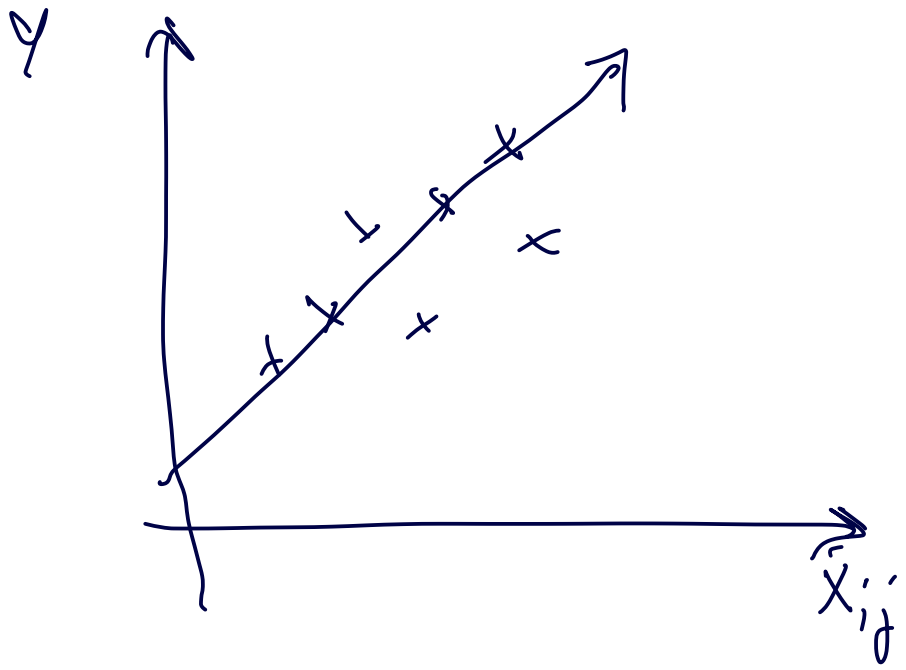
- INDEPENDANCE =

chaq. mesure est ind des autres

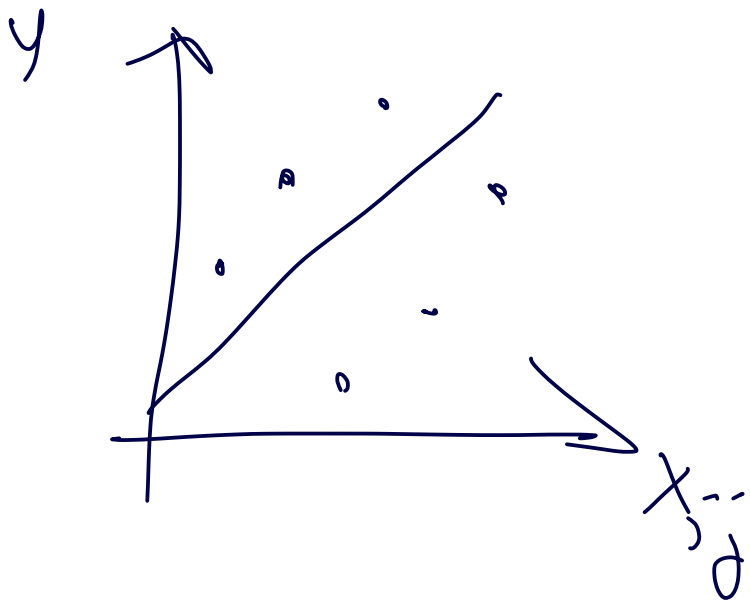
1) Hyp à vérifier

- **LINÉARITÉ** : $E(Y_{ik} | X_i) = \beta_{0k} + \sum \beta_{jk} X_{ij}$

Cas lin



Cas non lin



A x_j et k fixé, Y_{ik} suit une droite

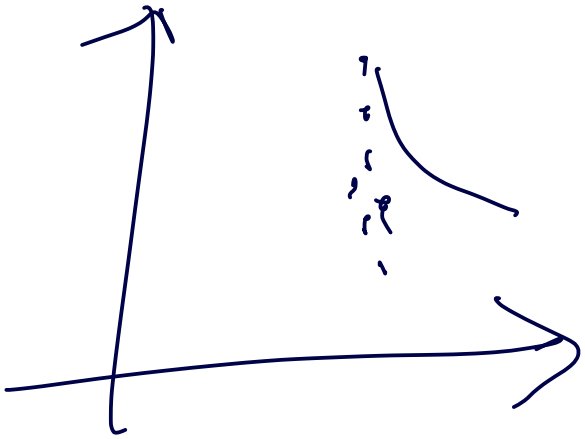
1) Les hyp à vérifier

- <u>NORMALITÉ</u> : $\varepsilon_{ik} | X_{ik} \sim \mathcal{N}_k(0, \Sigma)$.

Cas normal



Cas non normal

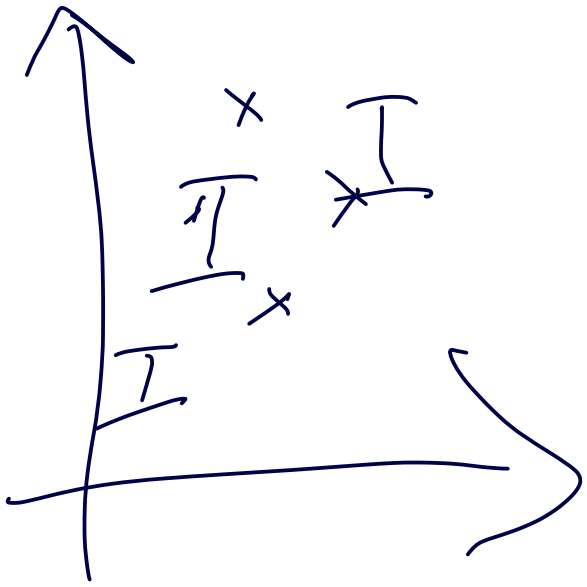


$\forall$ x_{ij} fixé, les y_{ik} sont normaux.

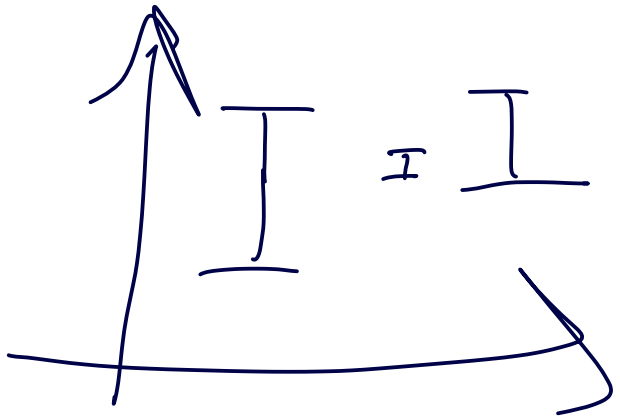
1) Les hyp à vérifier

- **HOMOSCEDASTICITÉ** : $Var(\varepsilon_i | X_i) = \Sigma$

cas homoscedastique



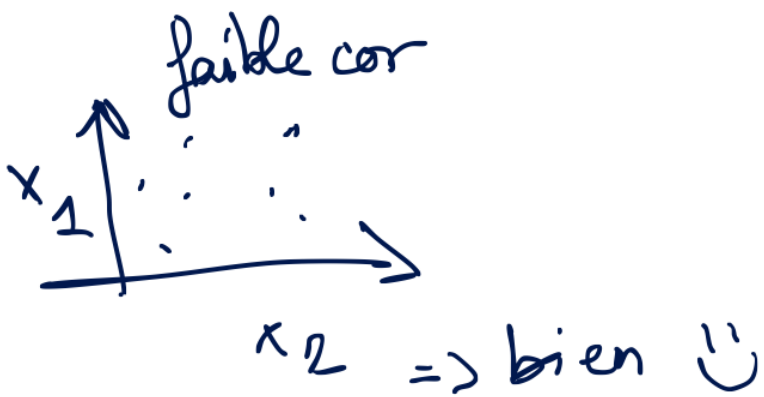
cas non homoscedastique



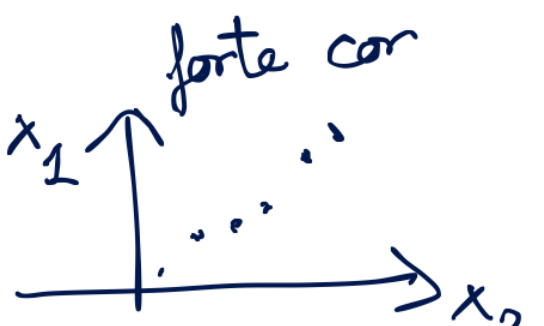
A axe fixé, la variance des Y est cste

1) les hyp a vérifier

NON MULTICOLINEARITÉ = aucune var explicative ne s'exprime comme une combinaison linéaire des autres.



=> bien ☺

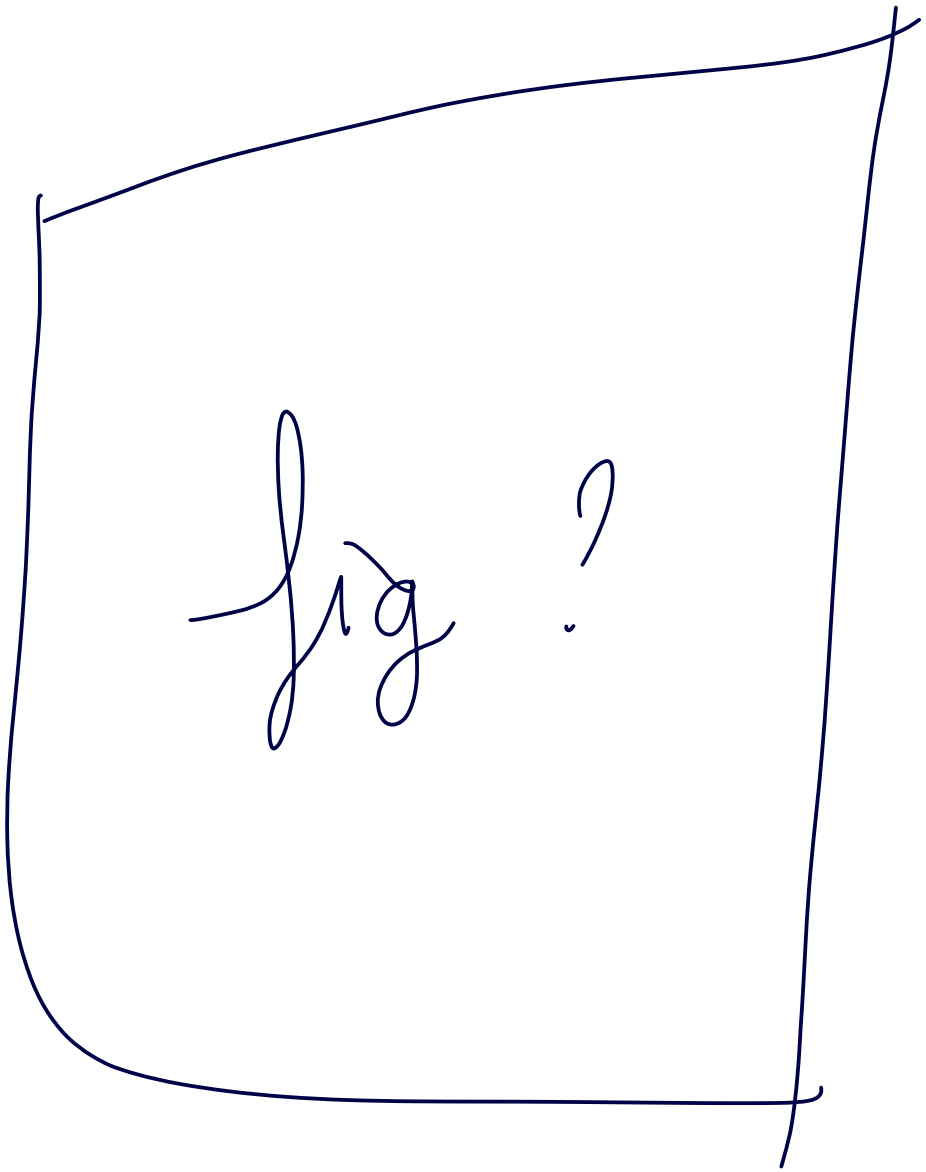


=> pas bien !!

Les variables X ne sont pas de comb. lin. les unes des autres

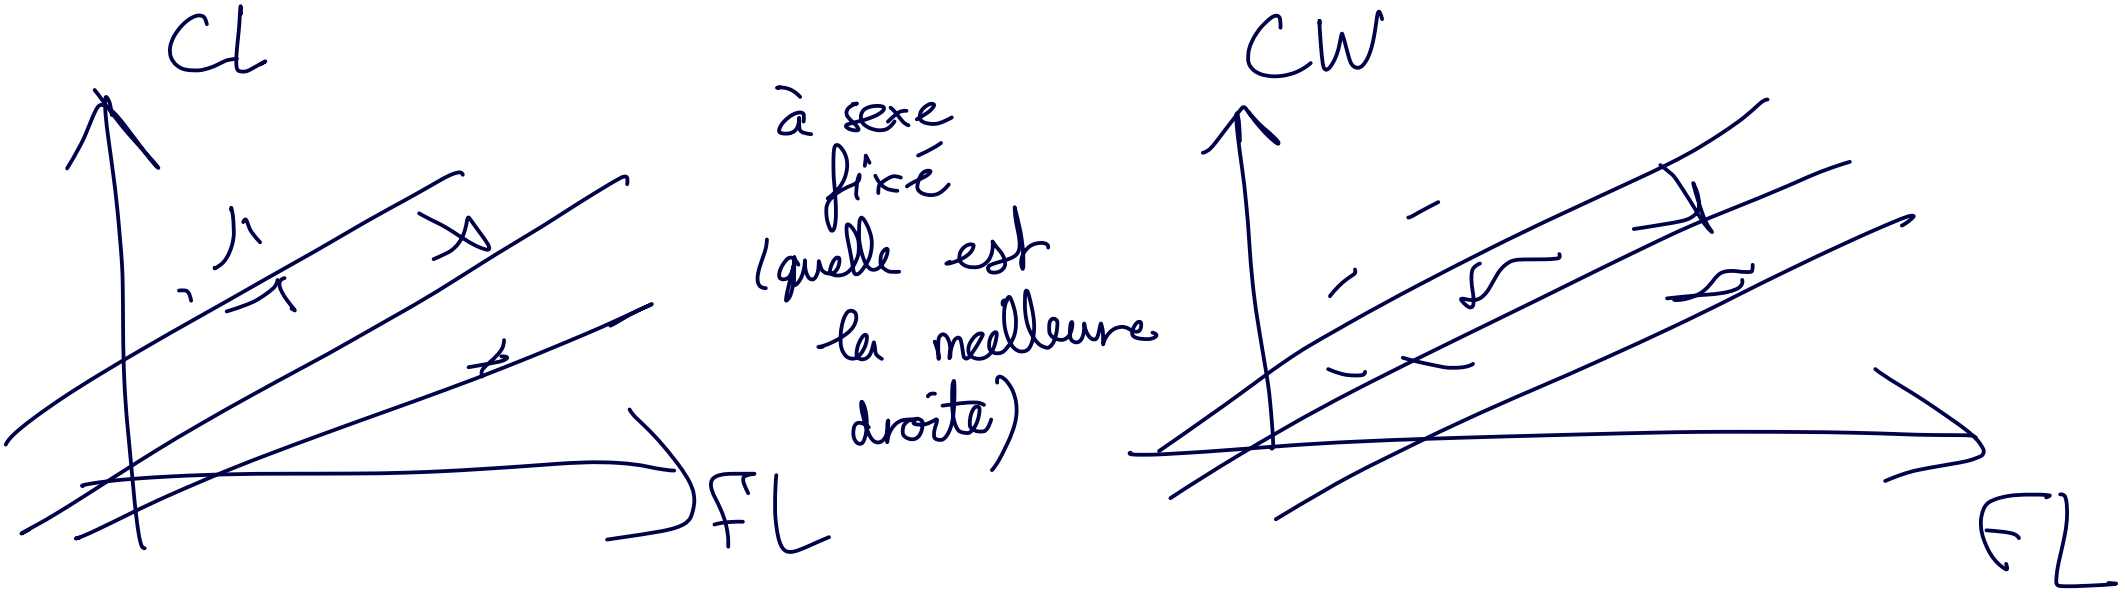
1) Vérifs des hyp sur les données de crabes

- INDEPENDANCE : ✓
- NORMALITÉ : ✓
- Homoscedasticité : ✓
- Absence de col : ✓



2) Méthode de Moindres carrés – Intuition

La reg. lin. multivariée permet de trouver la matrice β tq les données sont le mieux décrites



2) Méthode MC - Notations

- β matrice de params
  → $\hat{\beta}$ mat. estimée

- Y matrice des rep
  → $\hat{Y}$ mat estimée

on cherche les $\hat{\beta}$ tq

$$\hat{\beta} = \underset{\beta}{\operatorname{argmin}} \sum_{i=1}^{n} \sum_{k=1}^{K} \left(Y_{ik} - \hat{Y}_{ik} \right)^2$$

où $\hat{Y} = X\beta$.

2) Résolution

on cherche les $\hat{\beta}$ tq

$$\hat{\beta} = \underset{\beta}{\operatorname{argmin}} \sum_{i=1}^{n} \sum_{k=1}^{K} \left(y_{ik} - \hat{y}_{ik} \right)^2$$

où $\hat{y} = X\beta$.

En dérivant, on obtient comme solution :

$$\hat{\beta} = \left(X^T X \right)^{-1} X^T y$$

Note

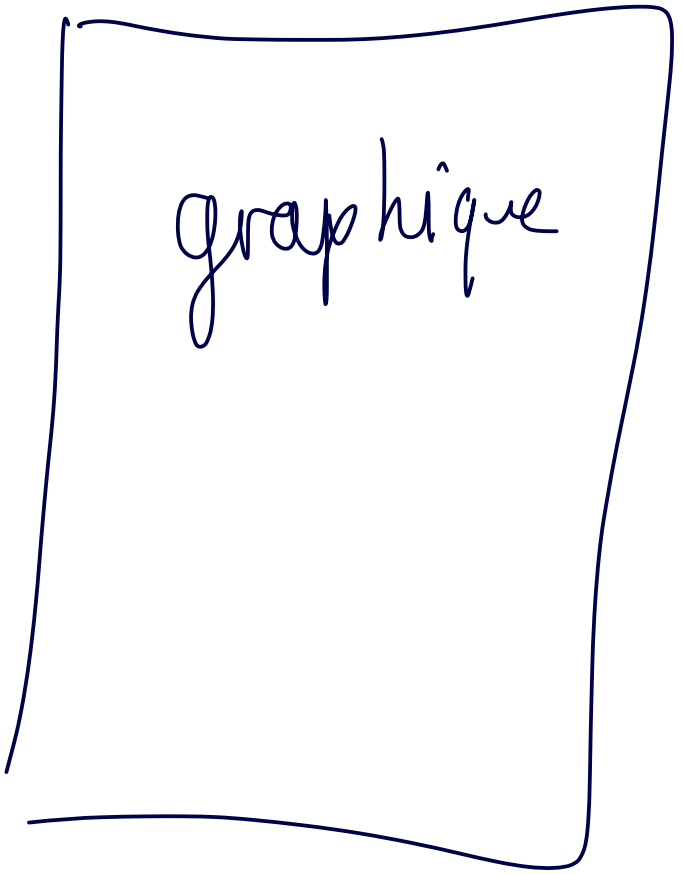
c'est pareil que si on faisait des reg individuelles

⇒ en pratique, on résout numériquement.

2) Résolution – Exemple

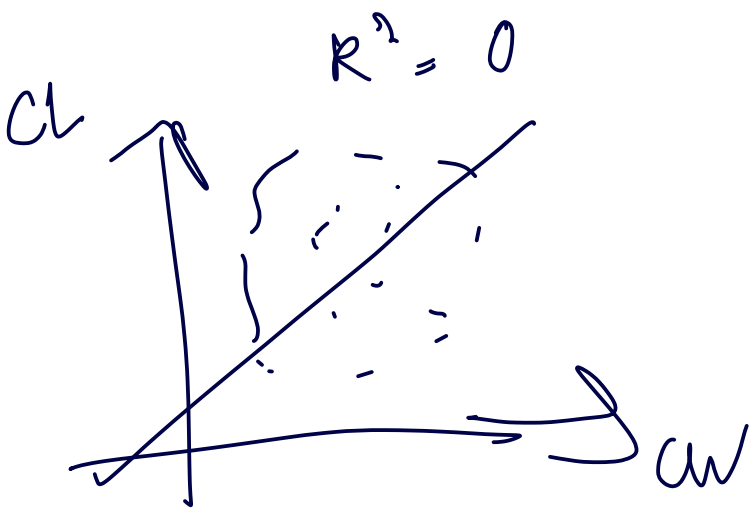
$\hat{C_L} =$

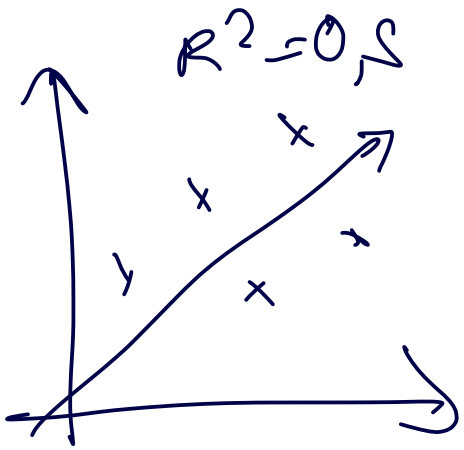
$\hat{C_W} =$

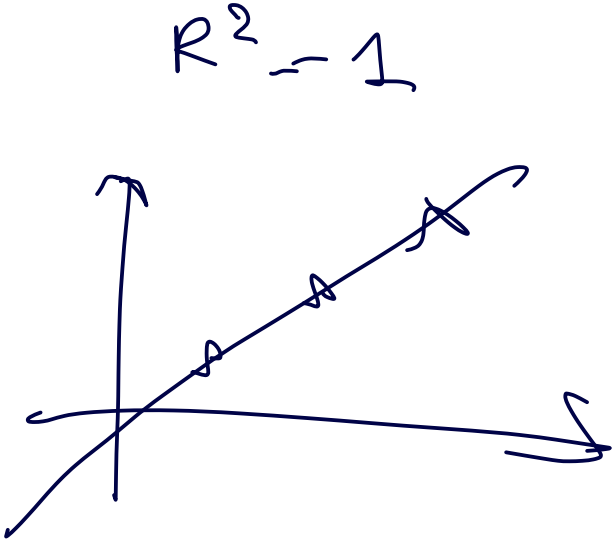


3) Le R^2

Le R^2 mesure le % de var d'une réponse expliquée par le modèle







Attention

On calcule 1 R^2 pr chaque rep k

$0 < R^2_k < 1$.

3) Le R^2 calcul

3 Qualité de la droite de régression avec R^2 : Calcul

$$R^2 = \frac{\sum_{i=1}^{N} (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^{N} (\hat{y}_i - y_i)^2} = 1 - \frac{\sum_{i=1}^{N} (y_i - \bar{y})^2}{\sum_{i=1}^{N} (y_i - \bar{y})^2},$$

où :

- $\sum_{i=1}^{N} (\hat{y}_i - \bar{y})^2$ = somme des carrés expliqués
  $\longrightarrow$ Ce que le modèle **EXPLIQUE.**
- $\sum_{i=1}^{N} (y_i - \bar{y})^2$ = somme des erreurs/résidus
  $\longrightarrow$ Ce que le modèle **N'EXPLIQUE PAS.**
- $\sum_{i=1}^{N} (y_i - \bar{y})^2$ = variabilité totale
  $= \sum_{i=1}^{N} (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^{N} (\hat{y}_i - y_i)^2.$

3) Note de R^2 ajusté

$$R^2_{\text{ajusté}} = 1 - (1 - R^2_k)\frac{n-1}{n-J-1}$$

→ prise en compte du nb de var exp. (J)

→ utile pour comparer ≠ modèles avec des nb de vars ≠

3) Calcul du R^2 exemple

$R^2_{k,a}$ =

R^2_k ajusté =

.

,

!

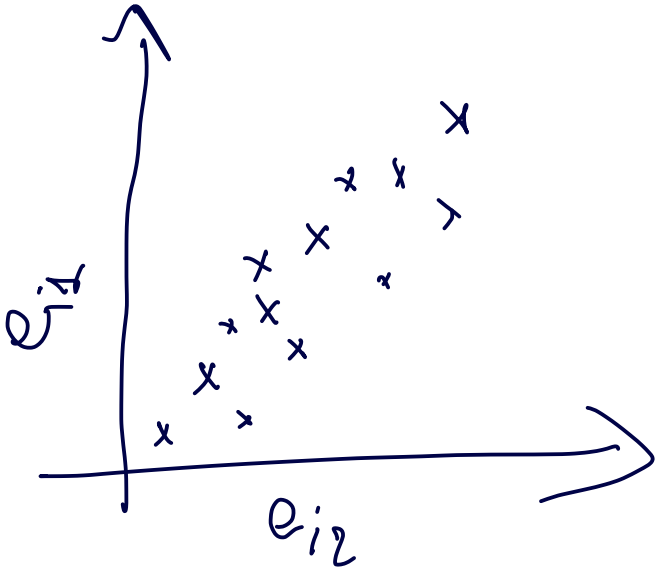


4) Rq ne pas juste faire 2 regressions linéaires !! ? Intuition

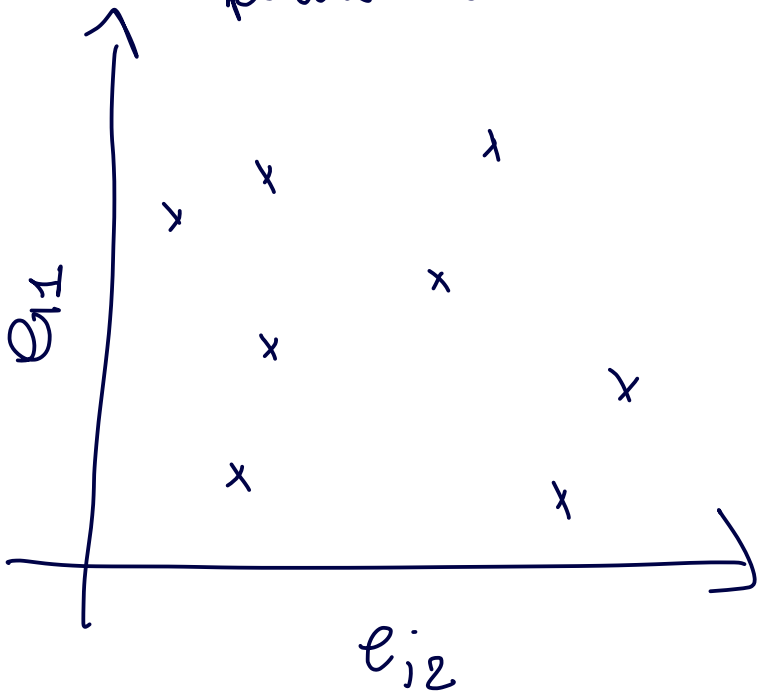
On se place dans le cas d'une analyse de 2 rep Y_1, Y_2. On pose

$$e_{ik} = Y_{ik} - \hat{Y}_{ik}$$

Residus corrélés (corr > 0)



Résidus non corrélés



Note

Il y a une dep entre les réponses - la reg multivariée permet de tenir coté des corrélations entre les résidus pour réaliser des tests conjoints.

4) Prendre en compte les corrélations résiduelles

ERREURS =

$$\varepsilon_i = \begin{pmatrix} \varepsilon_{i1} \\ \varepsilon_{ik} \end{pmatrix} \text{ tq } \varepsilon_i \sim \mathcal{N}_k(0, \Sigma) \quad \text{où}$$

$$\Sigma = \begin{pmatrix} \sigma_1^2 & \cdots & \sigma_{1k} \\ \vdots & \ddots & \vdots \\ \sigma_{1k} & \cdots & \sigma_k^2 \end{pmatrix}$$

cov $= 0$ pas de corrélation
> 0 corr > 0
< 0 corr < 0

var $(t_{js} > 0)$

Contrairement à des reg $\perp$, la reg multivariée permet d'estimer les liens entre les erreurs

4) Pour aller + loin = Tester conjointement les effets des vars

Q = La longueur FL est-elle conjointement associé à CL et CW ?

Hyp = $H_0 = \beta_{FL,CL} = \beta_{FL,CW} = 0$ $\quad H_1 = \exists 1 \text{ tq } \beta_{FL,CL} \neq \text{ou} \neq \beta_{FL,CW} \neq 0$

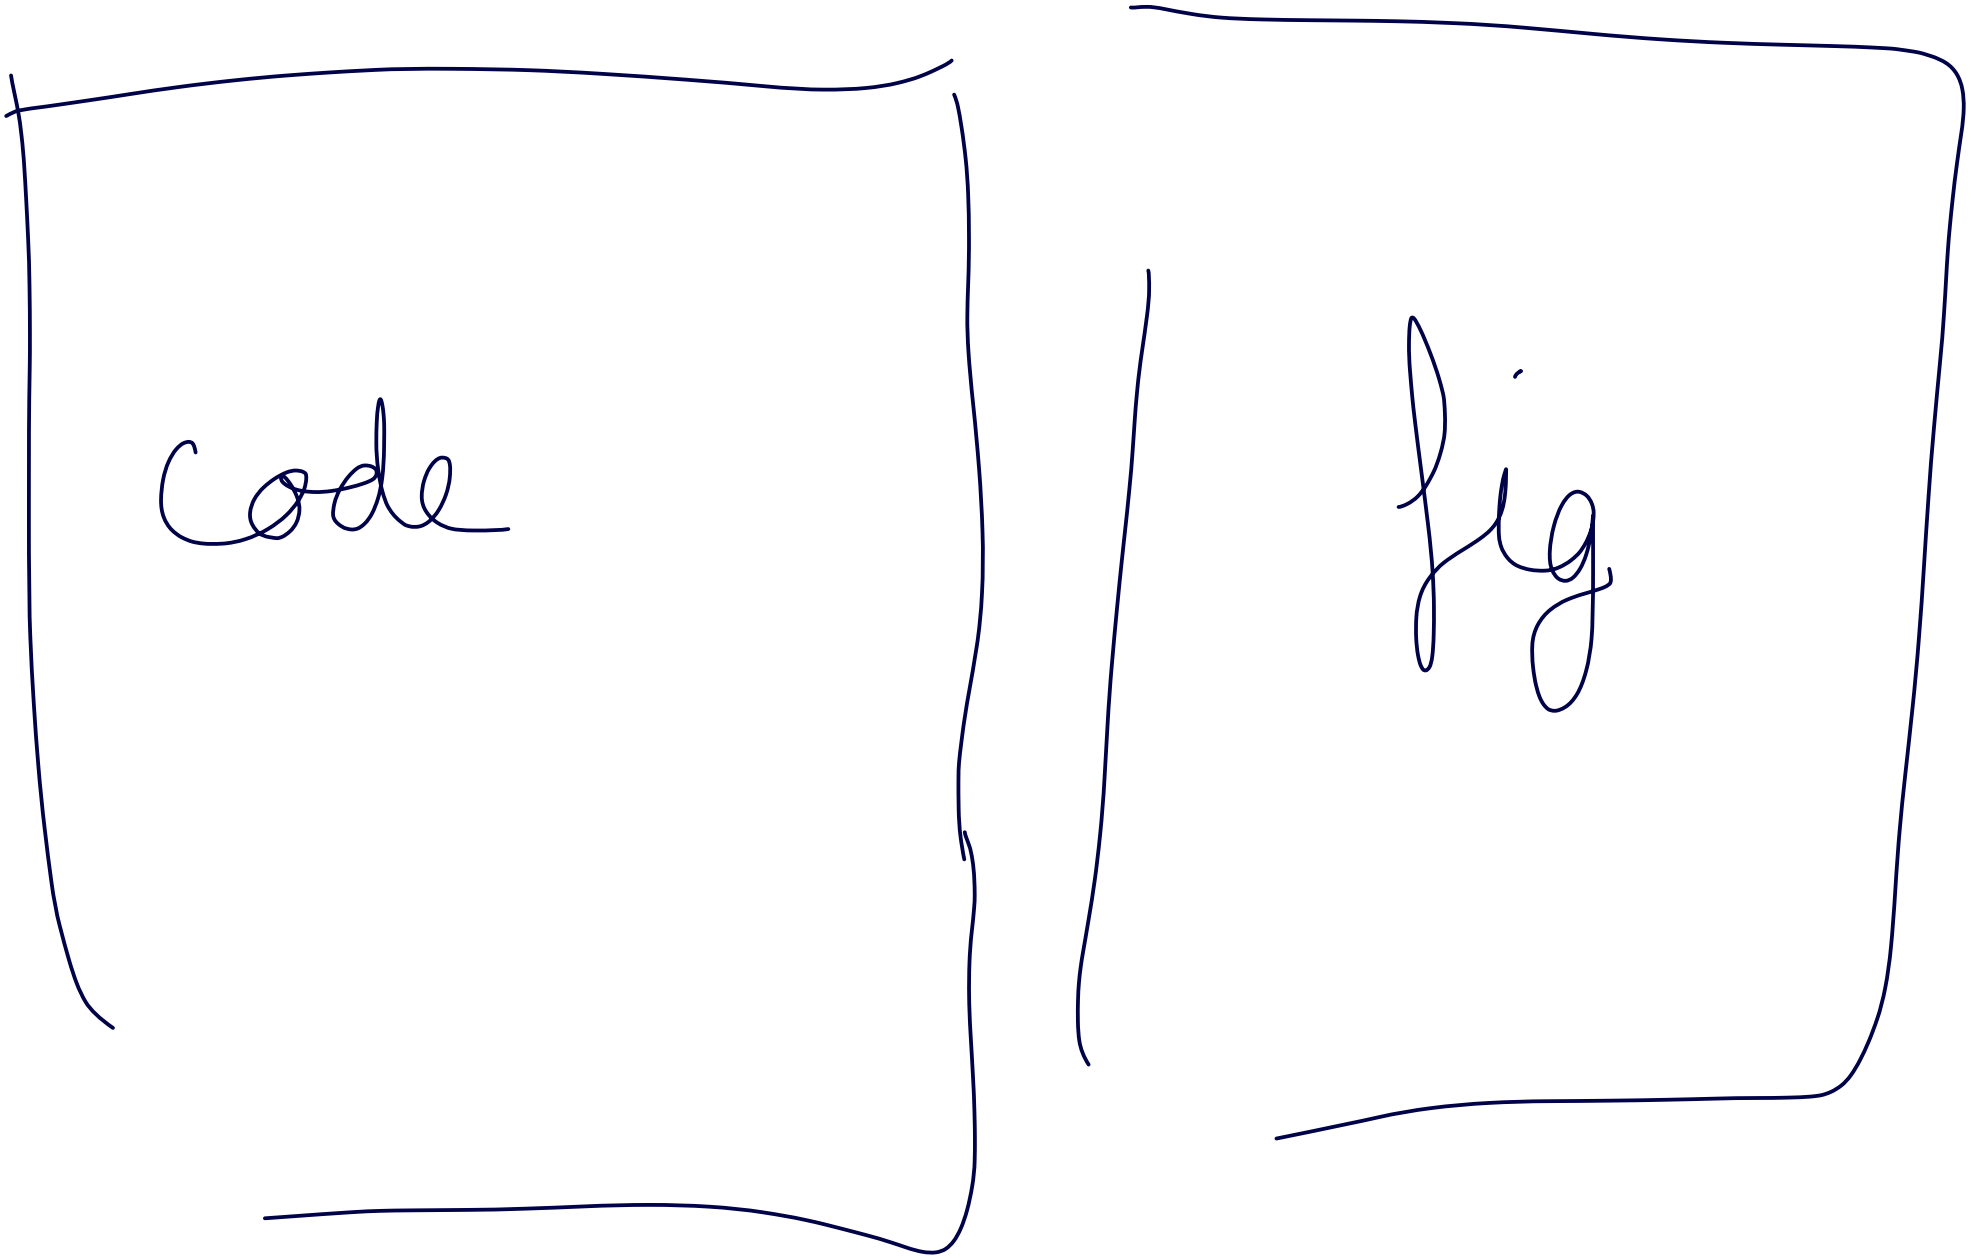
→ Si on veut faire on fait un test MV de Pillai.

5) Application avec R

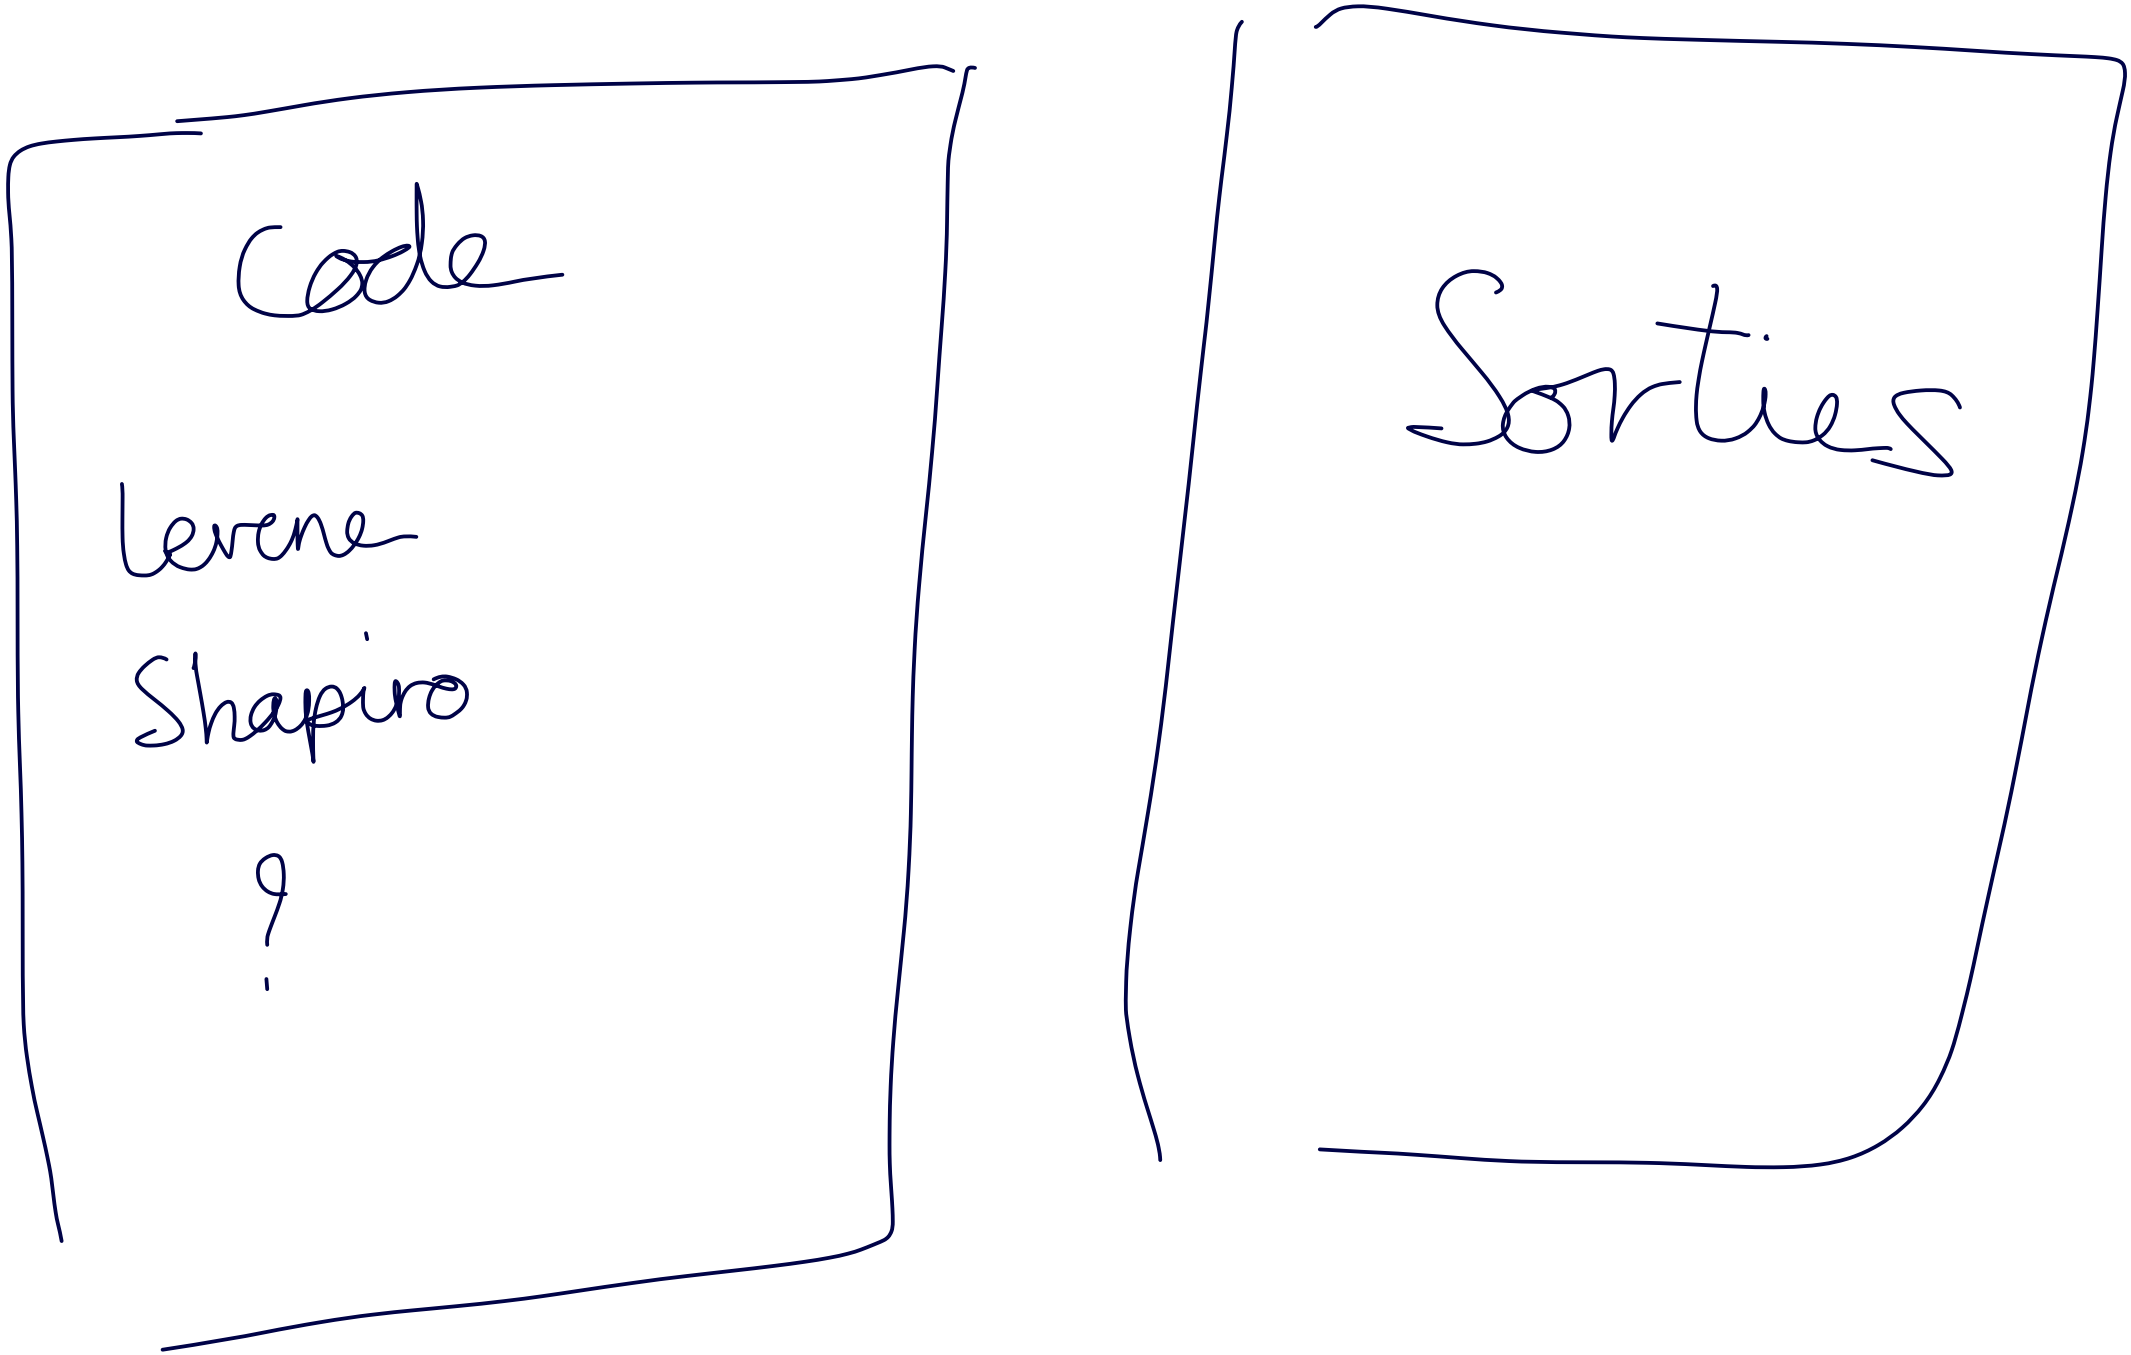
To Do :

1. Visualiser les données
2. Vérifier les hyps
3. Faire la reg
4. Conclure

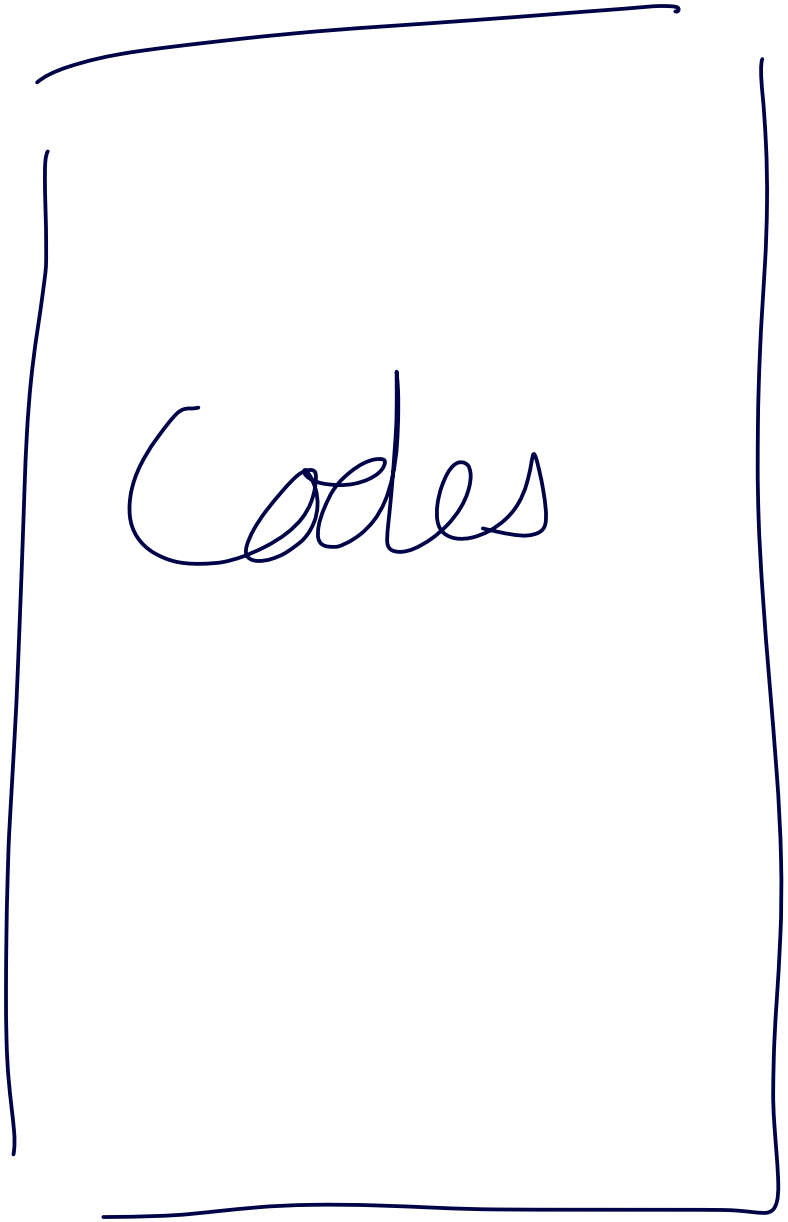
5) Appli - Visu



5) Appli - Vérifs hyps



5) Appli - GLM





5) Appli - Conclu

