Machine learning pour le traitement de données de grande dimension dans le domaine des sciences du vivant

AgroParisTech - 2ème année

Sarah Lemler

2026

Prérequis :

- cours de 1 A Modélisation mathématique et ses applications : statistiques - mise en oeuvre continue
- cours de 2A Sciences des données : apprentissage statistique

Organisation et évaluation de l'UE

Cette UE de 48h alternera :

- Cours (18h): concepts méthodologiques et fondements théoriques,
- Travaux dirigés (9h): exercices et prise en main des méthodes,
- Travaux pratiques (15h): analyse de jeux de données réels en sciences du vivant,
- Défis de type Kaggle (6h): plusieurs compétitions pour comparer les approches et apprendre à construire un pipeline d'analyse (avec accès à un centre de calcul commun)

Évaluation :

- prise en compte des performances sur les défis Kaggle,
- soutenance orale sur un défi choisi aléatoirement,
- examen écrit portant sur les concepts méthodologiques.

$$\text{Note finale} = 0.25 \times \text{performances} + 0.25 \times \text{oral} + 0.5 \times \text{examen}$$

☞ The Elements of Statistical Learning: Data Mining, Inference, and Prediction, Hastie, Tibshirani, Friedman

Pourquoi cette UE ?

Les sciences du vivant produisent aujourd'hui des données de plus en plus riches.

Type de données	n	p
Transcriptomique	50–500	$\sim 20\,000$
Génomique / SNP	100–1000	$10^5 - 10^6$
NIRS	quelques centaines	plusieurs milliers
Imagerie	variable	très grande dimension

$$p \gg n$$

Comment construire des modèles fiables et interprétables ?

Objectif de l'UE

A la fin de cette UE vous serez capable de :

- reconnaitre les limitations des méthodes statistiques liées aux défis de la grande dimension (→ ce cours introductif)
- comprendre le fonctionnement théorique et les propriétés des grandes familles de méthodes de ML (→cours méthodologiques)
- résoudre analytiquement et démontrer certaines propriétés (→ travaux dirigés)
- implémenter numériquement et interpréter les résultats obtenus (→ travaux pratiques sur données simulées et réelles)
- sélectionner les méthodes appropriées pour répondre à un problème biologique posé et les mettre en oeuvre dans un contexte réaliste (→ projet final)

Les limites de la grande dimension dans les méthodes statistiques standards

Objectifs du cours introductif

A l'issue de cette séance, vous devrez être capables de :

- identifier ce que l'on appelle des données de grande dimension,
- comprendre les principaux défis statistiques associés,
- relier des questions biologiques à des méthodes statistiques,
- comprendre pourquoi le machine learning est utile dans ce contexte.

Plan du cours

1. Le contexte de la grande dimension
2. Un premier obstacle, le mauvais conditionnement de la matrice de données
   - Application à un problème de régression
   - Le fléau de la corrélation en grande dimension
3. Un deuxième obstacle : une variance qui explose
   - Le compromis biais-variance
   - Application à un problème de classification
4. Troisième obstacle : le surapprentissage
5. Quatrième obstacle : les distances en grande dimension
6. Les limites des méthodes classiques de réduction de dimension
   - Choix de modèles
   - ACP

Qu'appelle-t-on la grande dimension ?

On observe une matrice de données :

$$X = \begin{pmatrix} x_{11} & \cdots & x_{1p} \\ \vdots & & \vdots \\ x_{n1} & \cdots & x_{np} \end{pmatrix}$$

où :

- n est le nombre d'individus,
- p est le nombre de variables.

En statistique classique, on a souvent :

$$n \gg p.$$

En sciences du vivant, on rencontre souvent :

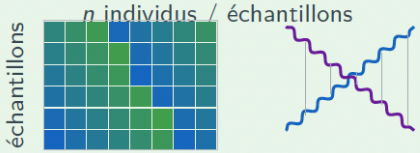
$$p \gg n.$$

Sciences du vivant en grande dimension : $p \gg n$

Contexte statistique

$p \gg n$

p variables biologiques
n individus / échantillons



gènes, variants, métabolites, OTU...

Objectif : extraire un signal biologique robuste malgré bruit, corrélations et faible n.

Application	Exemples de données $p \gg n$	Questions biologiques / méthodes
Agronomie	SNPs, marqueurs génomiques, phénotypage haut débit, images drones	**supervisé** prédire rendement, tolérance sécheresse, qualité ; identifier marqueurs associés. Variable cible : rendement, maladie, stress.
Biologie végétale	transcriptomes RNA-seq, métabolomique, épigénome, imagerie racinaire	**non supervisé** découvrir modules de co-expression, états de développement, réponses au stress. Existe-t-il des sous-groupes ou voies activées ?
Biologie animale	génomique de sélection, microbiome, comportement connecté, protéomique	**supervisé** classer animaux résistants/sensibles ; prédire croissance ou fertilité. **non supervisé** typologies de microbiotes.
Santé / biomédical	expression génique, variants rares, imagerie médicale, dossiers patients, single-cell	**supervisé** diagnostic, pronostic, réponse au traitement. **non supervisé** sous-types moléculaires, trajectoires cellulaires.
Alimentation / nutrition	spectrométrie, métabolites, microbiote alimentaire/intestin, profils sensoriels	**supervisé** authentifier une origine, prédire qualité ou risque sanitaire. **non supervisé** regrouper aliments ou profils nutritionnels.

Supervisé : Y connu
classification, régression, sélection de variables

validation biologique

Non supervisé : pas de Y
clustering, ACP/PLS, réseaux, facteurs latents

- Question : "Que veut-on prédire ?"
  → Méthodes supervisées (classification, régression, sélection de variables)
- Question : "Que peut-on découvrir dans les données ?"
  → Méthodes non supervisées (ACP, clustering, réseaux, facteurs latents)

Quelles méthodes pour quelles questions ?

Apprentissage supervisé

La variable réponse est connue.

- Prédire un rendement,
- Prédire un type de cancer,
- Sélectionner des biomarqueurs.

$\Rightarrow$ régression, classification

Apprentissage non supervisé

La réponse n'est pas connue.

- Découvrir des groupes,
- Etudier des similarités,
- Visualiser les données.

$\Rightarrow$ clustering, visualisation

Plan du cours

1. Le contexte de la grande dimension
2. Un premier obstacle, le mauvais conditionnement de la matrice de données
   - Application à un problème de régression
   - Le fléau de la corrélation en grande dimension
3. Un deuxième obstacle : une variance qui explose
   - Le compromis biais-variance
   - Application à un problème de classification
4. Troisième obstacle : le surapprentissage
5. Quatrième obstacle : les distances en grande dimension
6. Les limites des méthodes classiques de réduction de dimension
   - Choix de modèles
   - ACP

Le cas de la régression linéaire

Objectif : expliquer la production de riboflavine (vitamine B) à partir des niveaux d'expression de milliers de gènes (Données riboflavin).

- Observations : 71 souches (ou expériences).
- Variables explicatives : 4088 gènes, chacun représenté par son niveau d'expression.
- Variable réponse : une mesure quantitative de la production de riboflavine.

Le cas de la régression linéaire

Objectif : expliquer la production de riboflavine (vitamine B) à partir des niveaux d'expression de milliers de gènes (Données riboflavin).

- Observations : 71 souches (ou expériences).
- Variables explicatives : 4088 gènes, chacun représenté par son niveau d'expression.
- Variable réponse : une mesure quantitative de la production de riboflavine.

On peut représenter le problème par

$$Y = X\beta + \varepsilon,$$

où

- X est une matrice de dimension 71×4089
- Y est un vecteur de longueur 71,
- $\beta \in \mathbb{R}^{4089}$ représente les effets des 4088 gènes et l'intercept,
- $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_{71})$.

Un premier obstacle : un mauvais conditionnement de X^TX

Lorsque les variables sont nombreuses et/ou corrélées :

- la matrice X^TX est mal conditionnée,
- de petites variations des données peuvent produire de grandes variations des coefficients,
- l'interprétation biologique devient instable.

Exemples :

- gènes co-exprimés,
- SNP en déséquilibre de liaison,
- longueurs d'onde voisines en NIRS.

Application aux données riboflavin

Estimateur des moindres carrés :

$$\widehat{\beta} = (X^T X)^{-1} X^T Y.$$

```
> fit <- lm(y ~ X)
> summary(fit)
Call:
lm(formula = y ~ X)

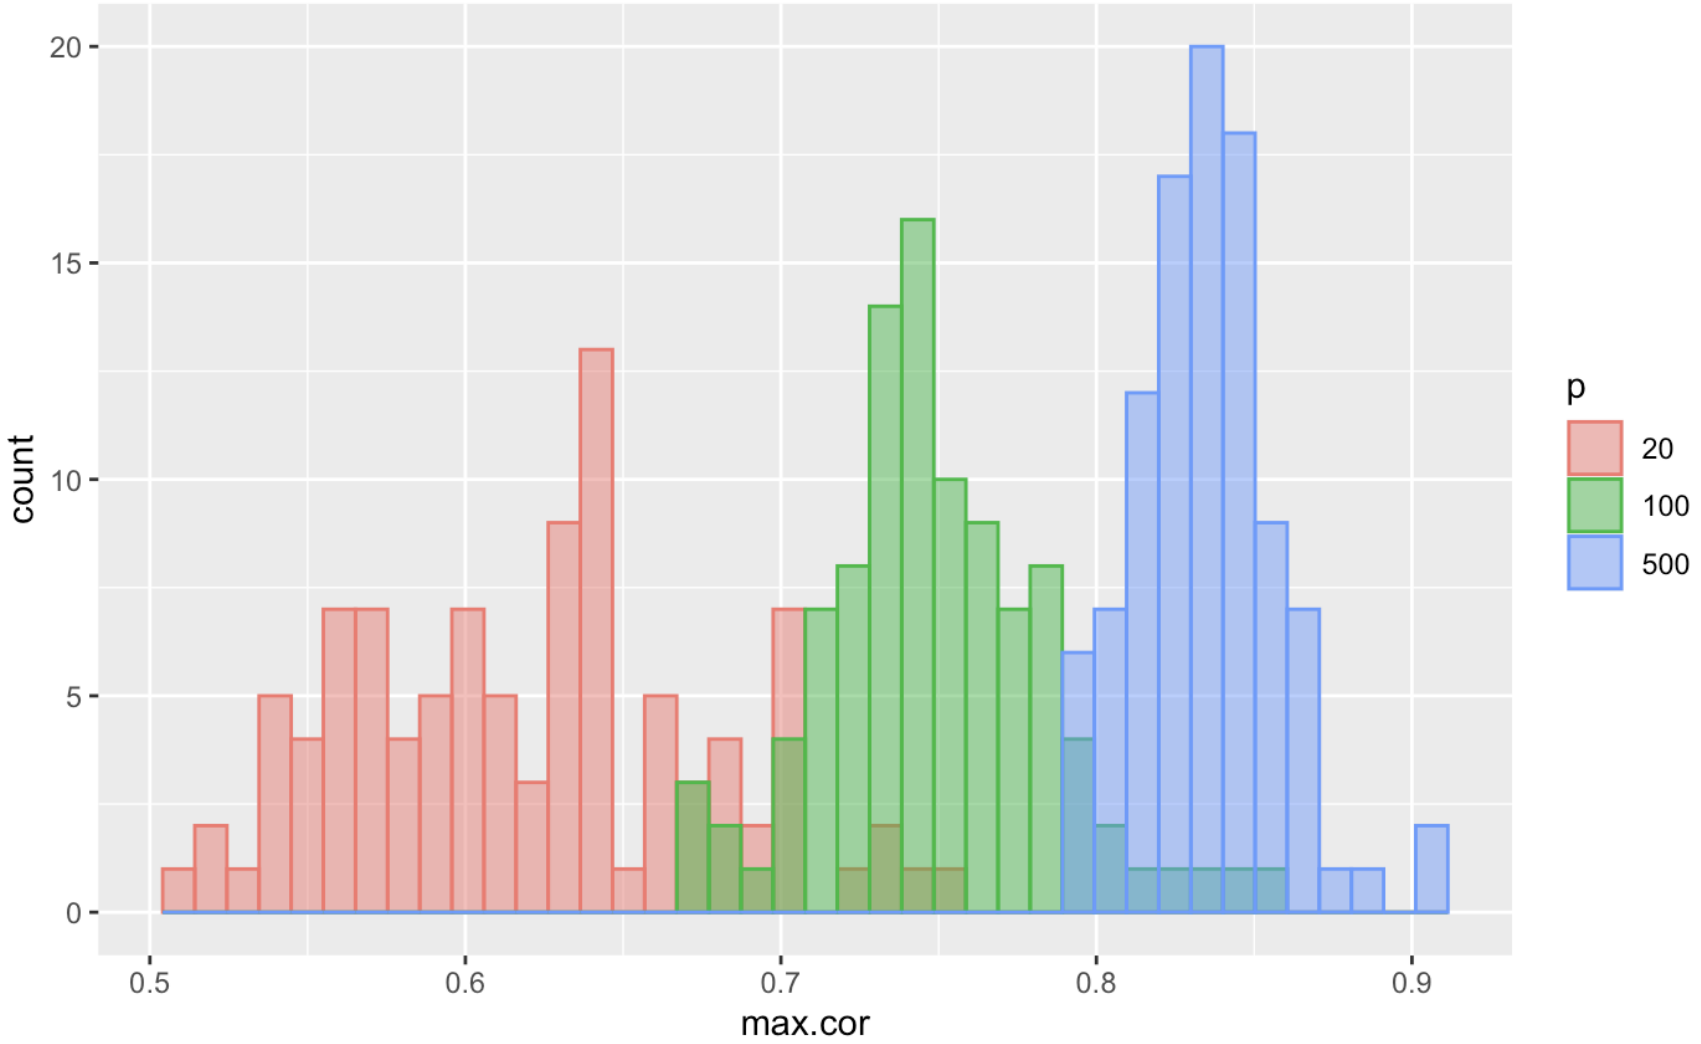
Residuals:
ALL 71 residuals are 0: no residual degrees of freedom!

Coefficients: (4018 not defined because of singularities)
```

La matrice $X^T X$ n'est pas inversible.

La méthode des moindres carrés ne peut plus être utilisée directement.

Le fléau de la corrélation en grande dimension



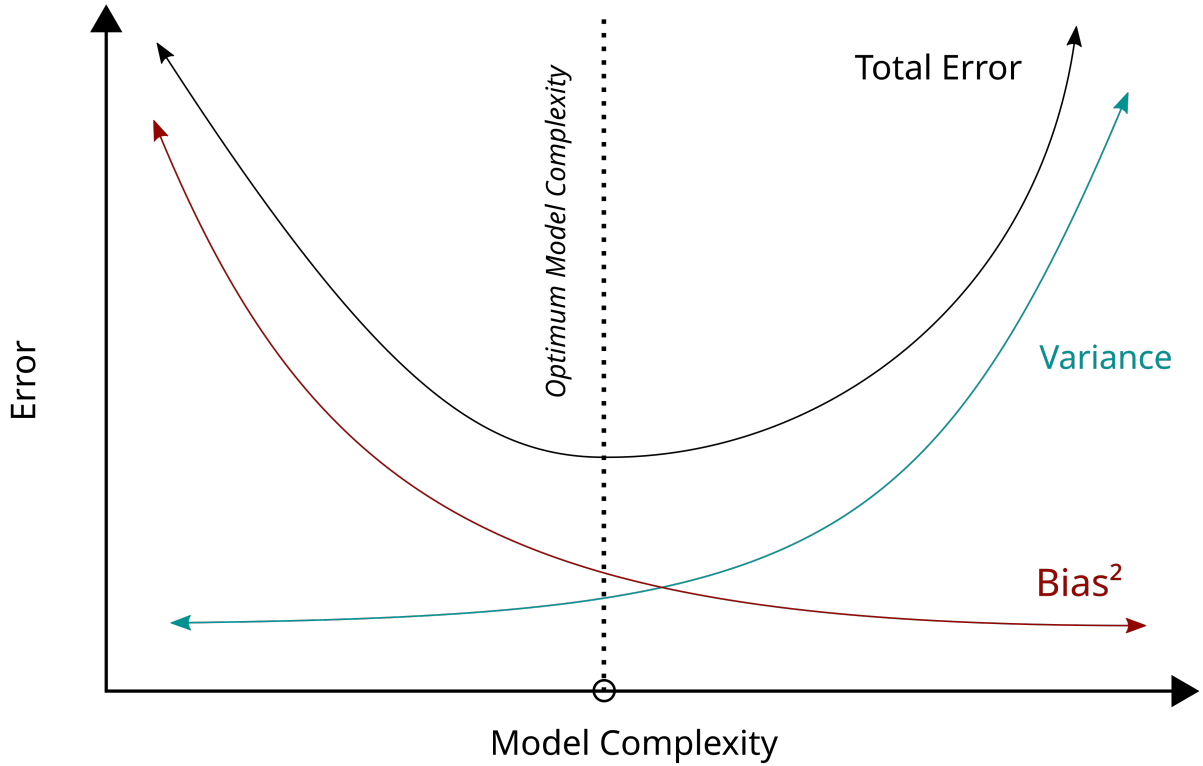
[1]

[1] figure de Julien Chiquet

Plan du cours

1. Le contexte de la grande dimension
2. Un premier obstacle, le mauvais conditionnement de la matrice de données
   - Application à un problème de régression
   - Le fléau de la corrélation en grande dimension
3. Un deuxième obstacle : une variance qui explose
   - Le compromis biais-variance
   - Application à un problème de classification
4. Troisième obstacle : le surapprentissage
5. Quatrième obstacle : les distances en grande dimension
6. Les limites des méthodes classiques de réduction de dimension
   - Choix de modèles
   - ACP

Le compromis biais-variance



Formule générale :

$$\mathbb{E}[\|X\hat{\beta} - X\beta\|^2] = \|\text{biais}(X\hat{\beta})\|^2 + \text{Tr}(\text{Var}(X\hat{\beta}))$$

Cas de l'estimateur des moindres carrés :

$$\frac{1}{n}\mathbb{E}[\|X\hat{\beta} - X\beta\|^2] = \frac{\sigma^2(p+1)}{n} \quad \Rightarrow \quad \text{en grande dimension, la variance explose}$$

Effet de la dimension sur la variance des estimateurs

Objectif : étudier l'effet du nombre de variables explicatives sur l'estimation d'un coefficient.

Simulation :

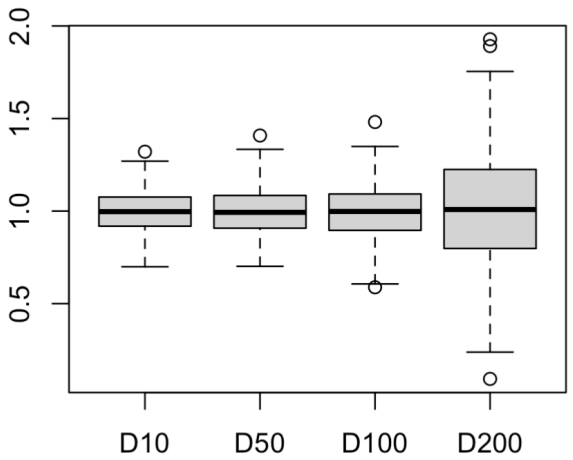
- On simule une matrice X de dimension $n = 250$ et $p = 1000$.
- La variable réponse dépend uniquement de la première variable :

$$Y = X_1 + \varepsilon, \qquad \varepsilon \sim \mathcal{N}(0, 0.5^2).$$

- On ajuste des modèles linéaires contenant X_1 et un nombre croissant de variables bruit :

$$d \in \{10, 50, 100, 200\}.$$

- L'expérience est répétée $B = 500$ fois.



Le cas de la classification

Objectif : prédire le type de tumeur d'un nouveau patient à partir de son profil d'expression génique (Données Small Round Blue Cell Tumours (SRBCT))

- Observations : 63 patients
- Variables explicatives : 2308 gènes mesurés pour chaque patient
- Variables réponse : le type de tumeur (EWS, BL, NB, RMS)

Le cas de la classification

Objectif : prédire le type de tumeur d'un nouveau patient à partir de son profil d'expression génique (Données Small Round Blue Cell Tumours (SRBCT))

- Observations : 63 patients
- Variables explicatives : 2308 gènes mesurés pour chaque patient
- Variables réponse : le type de tumeur (EWS, BL, NB, RMS)

On peut représenter le problème par un modèle de régression logistique multinomial :

$$\mathbb{P}(Y_i = k|X_i) = \frac{\exp(X_i^T \beta_k)}{\sum_{\ell=1}^{K} \exp(X_i^T \beta_\ell)},$$

où

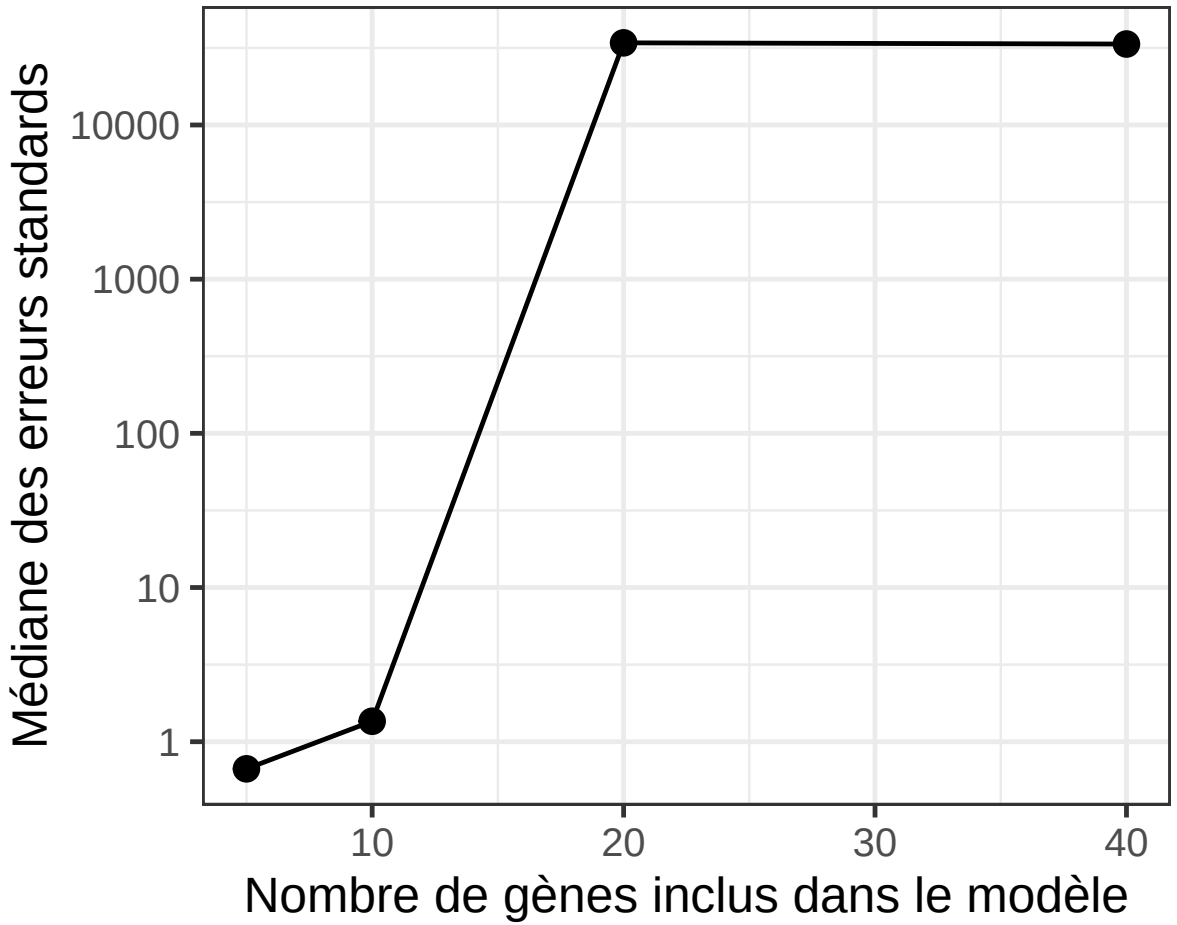
- $X_i = (1, X_{i1}, \ldots, X_{i2308})$ et X_{ij} représente le niveau d'expression du gène j.
- $Y_i \in \{\text{EWS, BL, NB, RMS}\}$, c'est-à-dire le type de tumeur,
- $\beta_k \in \mathbb{R}^{2309}$ pour $k \in \{1,2,3,4\}$.

Application à la classification

Avec $K = 4$ classes et $p = 2308$ gènes, on doit estimer

$$(K-1)(p+1) = 6927$$

paramètres avec seulement $n = 63$ patients.



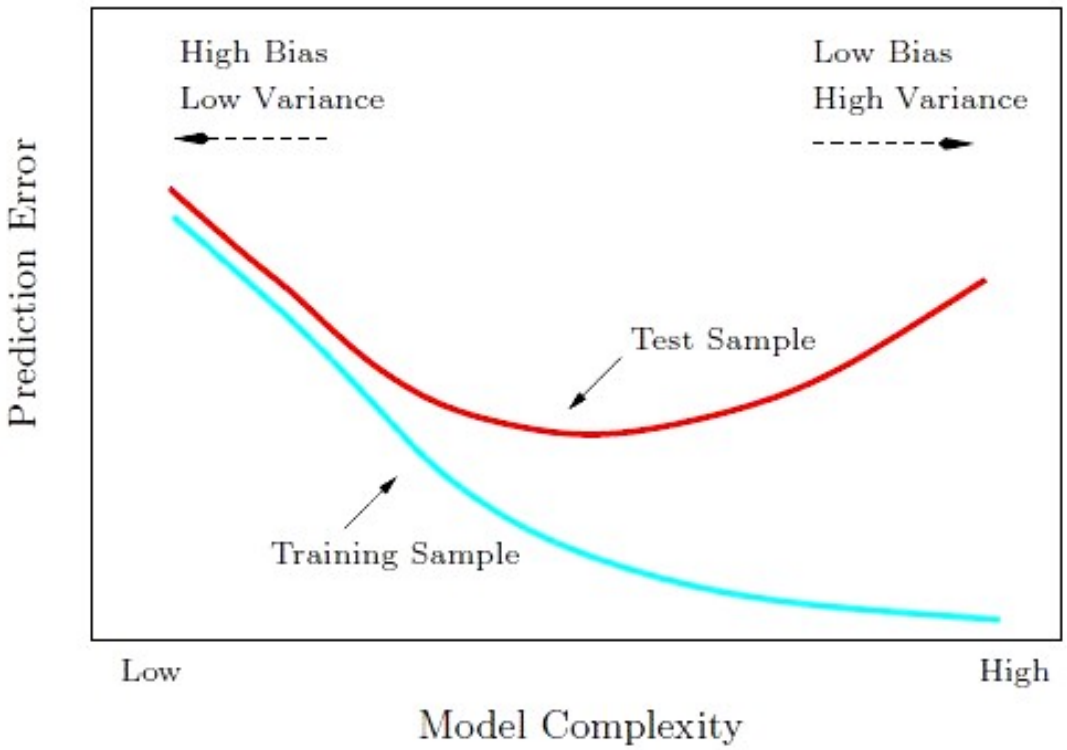
Plan du cours

1. Le contexte de la grande dimension
2. Un premier obstacle, le mauvais conditionnement de la matrice de données
   - Application à un problème de régression
   - Le fléau de la corrélation en grande dimension
3. Un deuxième obstacle : une variance qui explose
   - Le compromis biais-variance
   - Application à un problème de classification
4. Troisième obstacle : le surapprentissage
5. Quatrième obstacle : les distances en grande dimension
6. Les limites des méthodes classiques de réduction de dimension
   - Choix de modèles
   - ACP

Troisième obstacle : le surapprentissage

Avec beaucoup de variables, il est souvent possible de très bien expliquer les données d'apprentissage.

Mais ce n'est pas suffisant.



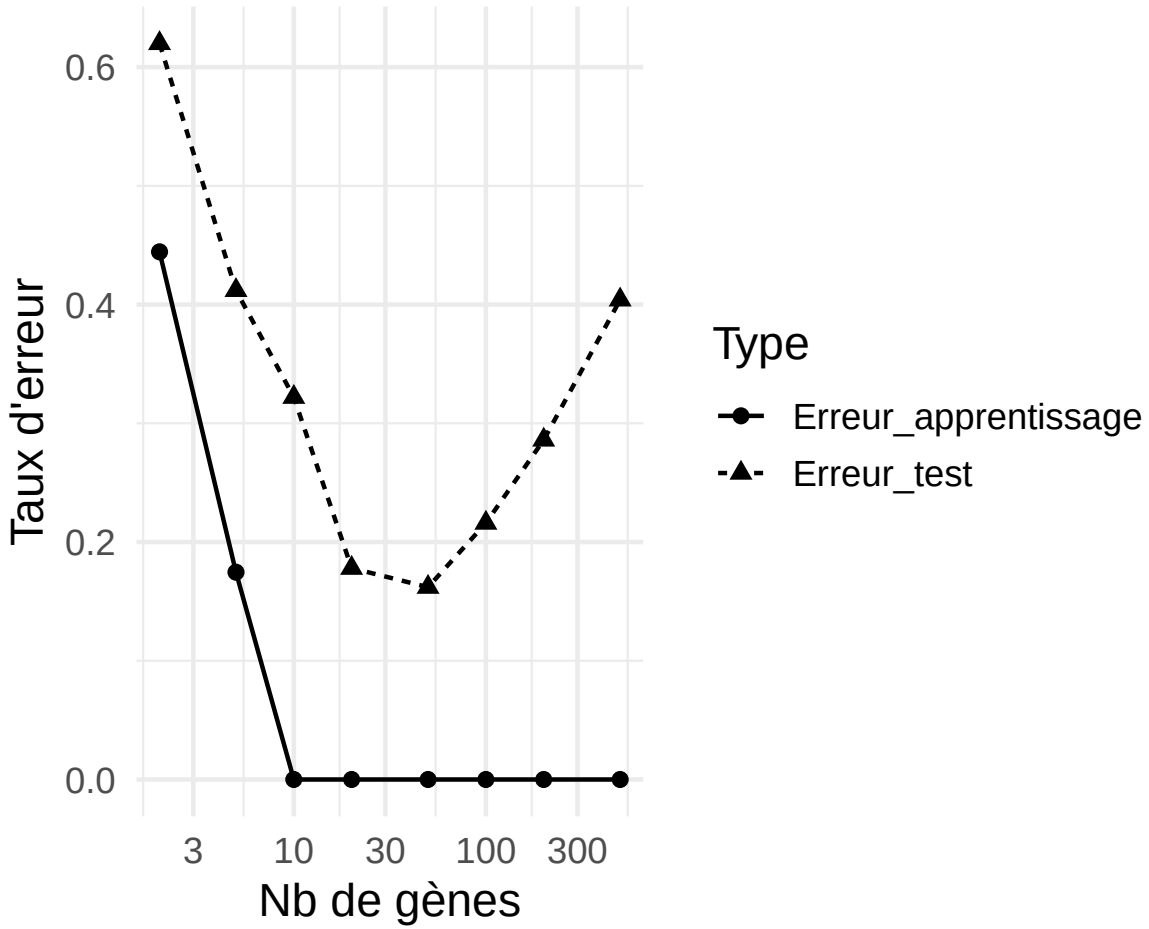
Un bon modèle doit prédire correctement de nouvelles observations.

Illustration du surapprentissage sur les données SRBCT

Expérience réalisée :

Nous simulons un jeu de données de même ordre de grandeur que SRBCT :

$$n = 63, \qquad p = 2308, \qquad K = 4.$$



Interprétation

Lorsque le nombre de variables augmente :

- l'erreur d'apprentissage diminue,
- mais l'erreur de prédiction ne diminue pas nécessairement,
- au-delà d'une certaine complexité, elle augmente : c'est le surapprentissage.

Bien ajuster les données $\neq$ Bien prédire de nouvelles observations.

Conséquence :
La performance d'un modèle doit être évaluée sur des données non utilisées pour son apprentissage.

Plan du cours

1. Le contexte de la grande dimension
2. Un premier obstacle, le mauvais conditionnement de la matrice de données
   - Application à un problème de régression
   - Le fléau de la corrélation en grande dimension
3. Un deuxième obstacle : une variance qui explose
   - Le compromis biais-variance
   - Application à un problème de classification
4. Troisième obstacle : le surapprentissage
5. Quatrième obstacle : les distances en grande dimension
6. Les limites des méthodes classiques de réduction de dimension
   - Choix de modèles
   - ACP

Quatrième obstacle : les distances en grande dimension

Dans de nombreuses méthodes non supervisées, on compare les individus via des distances.

Exemple :

$$d(i, i') = \left(\sum_{j=1}^{p} (x_{ij} - x_{i'j})^2 \right)^{1/2}.$$

Lorsque p est très grand :

- toutes les variables contribuent à la distance,
- le bruit s'accumule,
- les plus proches voisins peuvent ne plus être vraiment proches.

La grande dimension modifie la notion même de proximité.

Cas du clustering

Données SRBCT (63 patients, 2308 profils d'expression génique, 4 types de tumeur)

Question biologique : Existe-t-il des groupes naturels d'individus ?

Principe du clustering : regrouper les individus similaires.

Mais cela suppose que la notion de similarité soit pertinente.

En grande dimension :

- les distances deviennent moins discriminantes,
- les variables bruitées peuvent dominer,
- les groupes peuvent être artificiels,
- le résultat dépend fortement du prétraitement.

Méthode des K-means

Objectif :

- Partitionner les données en K groupes homogènes.
- Minimiser la variance intra-cluster :

$$\min \sum_{k=1}^{K} \sum_{i \in C_k} \|x_i - \mu_k\|^2,$$

où μ_k est le centroïde du cluster C_k.

Algorithme :

1. Choisir le nombre de clusters K et initialiser les centroïdes.
2. Affecter chaque observation au centroïde le plus proche.
3. Recalculer les centroïdes comme la moyenne des observations du cluster :

$$\mu_k = \frac{1}{|C_k|} \sum_{i \in C_k} x_i.$$

4. Répéter les étapes 2 et 3 jusqu'à convergence.

Application des K-means aux données SRBCT

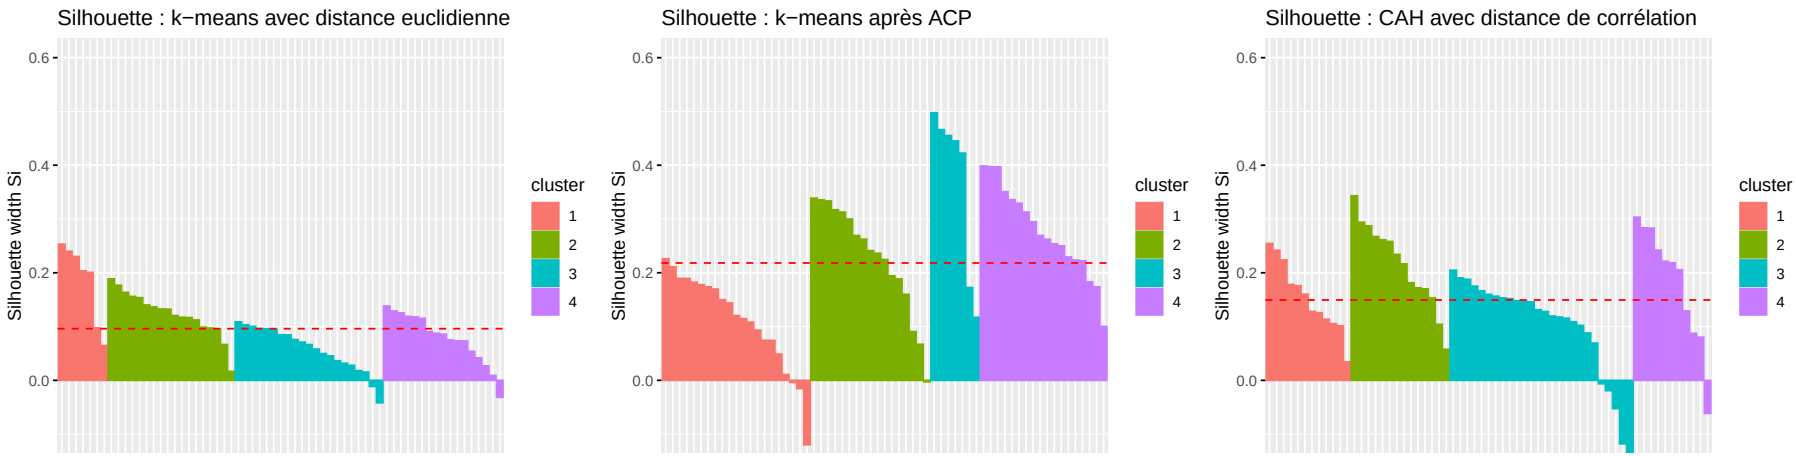
3 méthodes :

- K-means avec la distance euclidienne
- K-means après ACP avec la distance euclidienne
- CAH sur une distance de corrélation

Evaluation avec :

- le Adjusted Rand Index qui mesure la similarité entre deux partitions
- le coefficient de silhouette qui évalue la qualité du clustering sans utiliser les vraies classes

Les limites du clustering en grande dimension



	Methode	ARI	Silhouette_moyenne
1	K-means euclidien	0.08305658	0.09605318
2	K-means après ACP	0.08305658	0.21822144
3	CAH corrélation	0.15499242	0.14947294

Plan du cours

1. Le contexte de la grande dimension
2. Un premier obstacle, le mauvais conditionnement de la matrice de données
   - Application à un problème de régression
   - Le fléau de la corrélation en grande dimension
3. Un deuxième obstacle : une variance qui explose
   - Le compromis biais-variance
   - Application à un problème de classification
4. Troisième obstacle : le surapprentissage
5. Quatrième obstacle : les distances en grande dimension
6. Les limites des méthodes classiques de réduction de dimension
   - Choix de modèles
   - ACP

Méthode de choix de modèle

Problème :

Lorsque le nombre de variables explicatives augmente :

- de plus en plus d'informations sont prises en compte dans le modèle,
- le nombre de paramètres à estimer augmente et $\mathrm{Var}(\hat{Y}_i) \nearrow$.

Idée :

On cherche un (petit) ensemble $\mathscr{A}$ de k variables parmi les p disponibles tel que

$$Y \approx X_{\mathscr{A}}^T \hat{\beta}_{\mathscr{A}}.$$

Outils :

Pour trouver un compromis, il faut :

1. un critère permettant d'évaluer la qualité du modèle,
2. un algorithme permettant d'obtenir les k variables qui optimisent ce critère.

Critères pénalisés

Idée :

Plutôt que d'estimer l'erreur de prédiction à l'aide de l'erreur sur un échantillon test, on cherche à estimer de combien l'erreur d'apprentissage sous-estime l'erreur réelle.

Forme générale des critères :

Sans ajuster d'autres modèles, on calcule

$$\mathrm{err} = \widehat{\mathrm{err}} + \text{“optimisme”}.$$

Remarques :

- beaucoup moins coûteux que la validation croisée ;
- revient à pénaliser les modèles trop complexes.

Critères pénalisés

Soit k la dimension du modèle (nombre de variables explicatives).

On choisit le modèle de taille k qui minimise l'un des critères suivants :

- Critère d'information d'Akaike (AIC)
  Équivalent au critère de Mallows C_p lorsque σ est connu :

$$\text{AIC} = -2\text{loglik} + 2k$$

- Critère d'information bayésien (BIC)

$$\text{BIC} = -2\text{loglik} + k\log(n)$$

Sélection de sous-ensembles : recherche exhaustive

Algorithme

Pour $k = 0, \ldots, p$, on recherche le sous-ensemble de k variables qui minimise le critère AIC ou BIC parmi les $\binom{p}{k}$ modèles possibles.

$\hookrightarrow$ Devient rapidement impossible en pratique lorsque $p > 30$.

Sélection de sous-ensembles : recherche exhaustive

Algorithme

Pour $k = 0, \ldots, p$, on recherche le sous-ensemble de k variables qui minimise le critère AIC ou BIC parmi les $\binom{p}{k}$ modèles possibles.

↪ Devient rapidement impossible en pratique lorsque $p > 30$.

Trois méthodes approchées :

- Sélection progressive (*forward selection*) ;
- Sélection pas à pas (*forward-backward stepwise*) ;
- Élimination régressive (*backward elimination*).

↪ Méthodes gourmandes

Application en biologie animale

Objectif : expliquer le pourcentage de viande maigre d'une carcasse de porc (Lean Meat Percentage)

- $n = 117$ carcasses de porc.
- $p = 137$ variables explicatives : mesures du pourcentage de muscle obtenues à différentes positions anatomiques à partir d'images scanner.
- La dernière variable est le LMP, qui constitue la variable réponse.

```
> fit <- regsubsets(LMP~., data=pig,
+                   nvmax=20,
+                   method="forward")
Warning message:
In leaps.setup(x, y, wt = wt, nbest = nbest, nvmax = nvmax,
force.in = force.in,  :
  21  linear dependencies found
```

Visualisation : représenter l'information

Question biologique :

Comment visualiser des individus décrits par 2308 variables ?

L'ACP est un premier outil pour projeter les données :

$$\mathbb{R}^p \longrightarrow \mathbb{R}^2.$$

L'objectif de l'ACP est de construire une représentation de plus faible dimension qui conserve le maximum de variance.

Mais en grande dimension :

- les premières composantes peuvent être dominées par du bruit,
- les structures non linéaires sont difficiles à représenter,
- l'interprétation biologique peut être délicate.

Analyse en composantes principales (ACP)

Objectif : résumer l'information contenue dans un grand nombre de variables corrélées à l'aide d'un petit nombre de nouvelles variables non corrélées.

Principe :

- Construction de nouvelles variables appelées composantes principales :

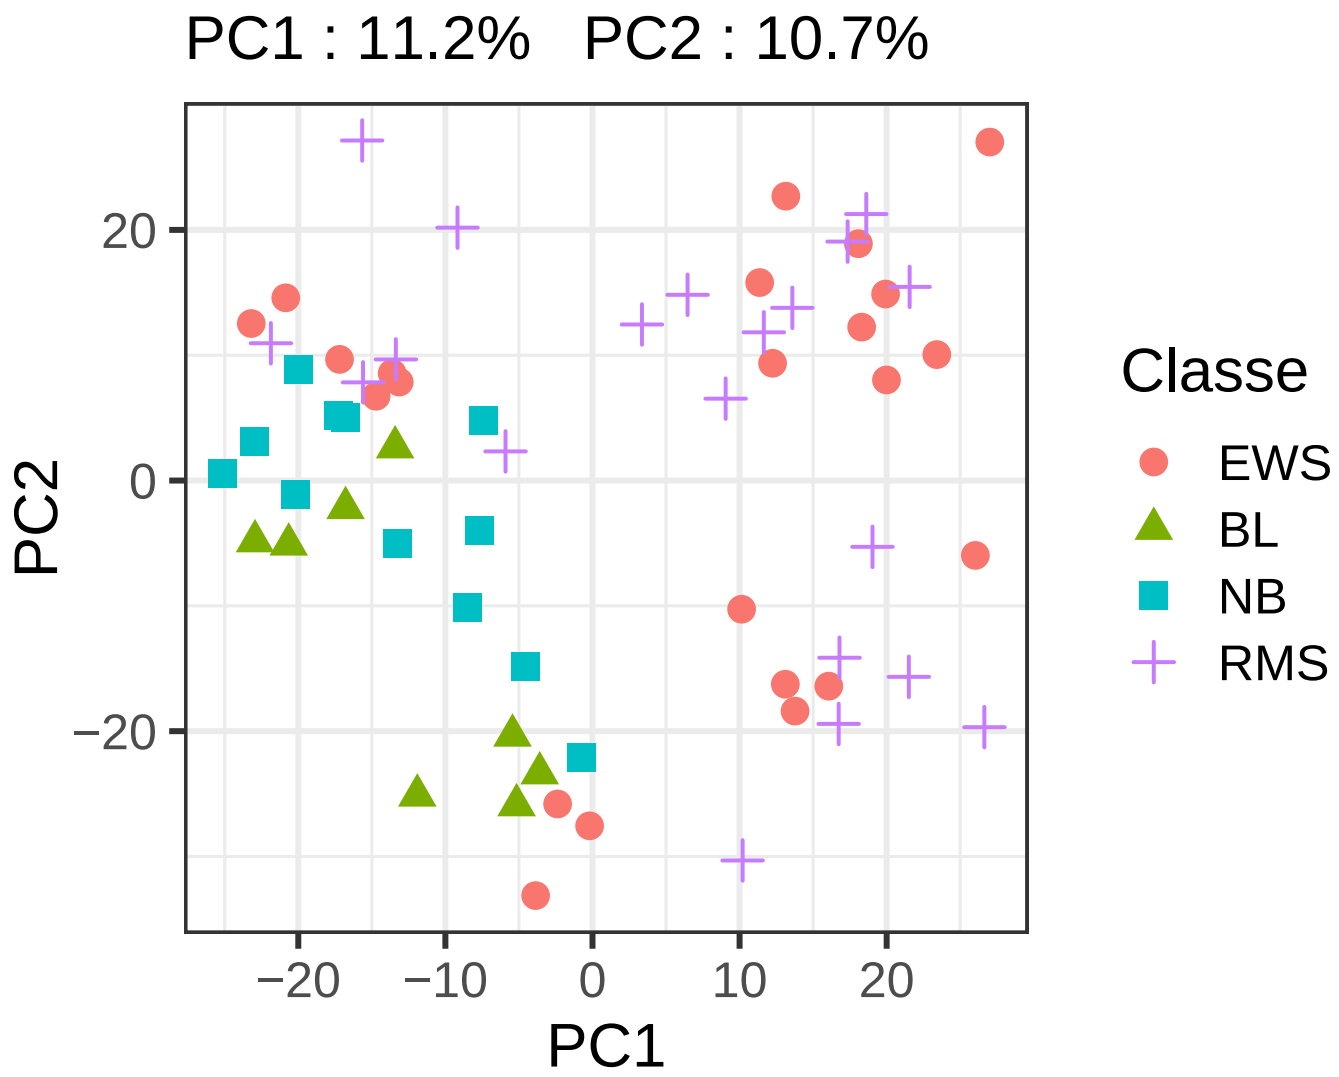
$$CP_k = Xa_k,$$

  où a_k est une combinaison linéaire des variables initiales.
- La première composante principale maximise la variance projetée.
- Les composantes suivantes maximisent aussi la variance, sous contrainte d'être orthogonales aux précédentes.

Interprétation :

- Chaque composante explique une part de la variabilité totale des données.
- Une faible variance expliquée par les deux premières composantes indique que l'information est répartie sur plusieurs dimensions.

Illustration sur les données réelles (SRBCT)



Résumé : les limites de la grande dimension

Méthodes	Questions	Difficultés principales
Régression	Prédire un rendement	$X^T X$ non inversible
Classification	Prédire une classe	Surapprentissage
Clustering	Découvrir des groupes	Distances peu informatives
Sélection	Trouver des biomarqueurs	Méthodes gourmandes
Visualisation	Représenter les données	Perte d'information

Ces difficultés motivent les méthodes de machine learning adaptées à la grande dimension.

Ce que nous apprendrons dans cette UE

Pour répondre à ces difficultés, nous étudierons :

- Section 1 : les méthodes supervisées en grande dimension
  - Chapitre 1 : les méthodes régularisées
    - ★ Régression Ridge pour gérer les corrélations
    - ★ Régression Lasso pour faire de la sélection de variables
    - ★ Variantes du Lasso

    Application : sélection de biomarqueurs en transcriptomique
  - Chapitre 2 : les méthodes de screening en ultra-grande dimension

    Application : données SNP (10^6 marqueurs)
  - Chapitre 3 : les méthodes d'ensembles
    - ★ Forêts aléatoires
    - ★ Importance des variables

    Application : Prédiction d'un rendement en fonction de biomarqueurs
  - Chapitre 4 : les méthodes de boosting
    - ★ Grandient boosting
    - ★ XGBoost

    Application : Prédiction du risque de maladie

- Section 2 : les méthodes non-supervisées en grande dimension
  - Chapitre 5 : L'ACP en grande dimension
    - ★ ACP parcimonieuse (Sparse PCA)
    - ★ ACP pénalisée
    - ★ ACP robuste

    Application : visualisation de données transcriptomiques
  - Chapitre 6 : Clustering
    - ★ K-means
    - ★ Classification hiérarchique
    - ★ Choix de la distance
    - ★ Evaluation (silhouette, ARI)

    Applications :
    - ★ découverte de sous-types tumoraux
    - ★ regroupement de cellules (Single-cell RNA-seq)
  - Chapitre 7 : Réduction de dimension non-linéaire
    - ★ MDS
    - ★ t-SNE
    - ★ UMAP

    Applications :
    - ★ visualisation de populations cellulaires par UMAP/t-SNE
    - ★ atlas cellulaires

Message central

La grande dimension n'est pas seulement un problème de taille des données.

Elle change les propriétés des méthodes statistiques.

Objectif de l'UE : apprendre à construire des analyses fiables, interprétables et reproductibles pour les sciences du vivant.